Estudo de técnicas de aprendizado de máquina na categorização de cogumelos venenosos

Kauã Alves Santos[1], **Mateus Vinicius Zebendo Pinto**[1,2]

[1]Centro Federal de Educação Tecnológica Celso Suckow da Fonseca – CEFET/RJ
Campus Nova Friburgo – Nova Friburgo, RJ – Brasil

13504982705@cefet-rj.com.br, 15674748705@cefet-rj.com.br

Resumo. ***Keywords:*** *Machine Learning, Decision Trees, Biological Safety, Data Classification.* ***Palavras-chave:*** *Aprendizado de Máquina, Aprendizado Supervisionado, Árvores de Decisão, Classificação Baseada em Revocação, Toxicidade de Cogumelos.*

1. Introdução

O artigo avalia algoritmos de aprendizado de máquina para a criação de um modelo de classificação supervisionada. O objetivo central é encontrar o algoritmos, entre os seis analisados, que minimize falsos negativos e priorize a Revocação [Van Rijsbergen 1986] sobre a acurácia bruta para a base em questão, a fim de diminuir a ingestão acidental ou equivocada de cogumelos *Agaricus* e *Lepiota*.

A base de dados em questão (dataset) utilizada nesse artigo foi a mushroom-classification [Schlimmer 1987]. Esse dataset, criado por Jeffrey Schlimmer em 1987, contém 8.124 registros de cogumelos gilled das famílias *Agaricus* e *Lepiota*. O termo *gilled* refere-se às lamelas de um cogumelo como mostrado na figura 1 e explicado na Seção 1.1.

O desafio fundamental do artigo é a classificação binária de espécimes em comestível ou venenoso, onde o grande gafe de predição ocorre quando uma espécie tóxica é classificada como comestível (Falso negativo). Esse risco biológico estabelece a Revocação (Recall) como a métrica determinante para a avaliação da melhor técnica de aprendizado de máquina para esse dataset. Para esse intuito, foram feitas análises de seis algoritmos:

- 1. K-Nearest Neighbours (KNN) [Cover 1968]
- 2. Naive Bayes [Hand and Yu 2001]
- 3. Decision Three (Árvore de decisão) [Quinlan 1986]
- 4. Random Forest [Breiman 2001]
- 5. Support Vector Machines (SVM) [Vapnik 1995] e
- 6. Redes Neurais [Rumelhart et al. 1986]

A avaliação comparativa desses seis algorítimos visa determinar não apenas o modelo com menor taxa de erro, mas aquele que oferece a maior estabilidade e adequação ao rigor exigido pelo contexto de segurança biológica.

Trabalho desenvolvido como requisito de avaliação da disciplina optativa de Técnicas de Aprendizado de Máquina (2026.1) do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca (CEFET/RJ) - Campus Nova Friburgo. O referencial metodológico para a concepção dos modelos baseou-se em Bruce [Bruce and Bruce 2017].

1.1. Biologia dos cogumelos

A família *Agaricus* compreende alguns dos fungos mais difundidos, incluindo o cogumelo de Paris ou Champignon (*Agaricus bisporus*). Morfologicamente, espécimes desta família caracterizam-se por apresentarem lamelas livres em relação ao estipe e esporos com coloração variando entre marrom-escuro e chocolate, características que fundamentam importantes atributos preditivos no dataset estudado.

Já a família *Lepiota* assume papel central na análise de segurança biológica e na métrica de Revocação deste estudo. O risco crítico de classificação reside na alta toxicidade de diversas espécies deste grupo, que contêm *amatoxinas* — octapeptídeos cíclicos responsáveis pela maioria dos envenenamentos fatais por fungos. Esta família apresenta frequentemente escamas no píleo (chapéu) e anel no estipe, características essas que se revelaram fundamentais para a distinção lógica da toxicidade.

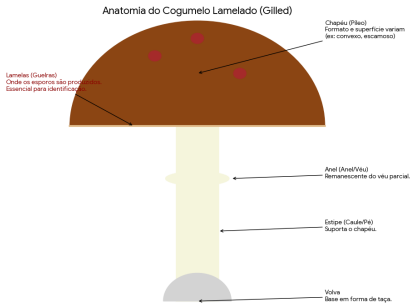

Figura 1. Anatomia de um cogumelo lamelado e suas partes principais.

2. Trabalhos Relacionados

Para a revisão de trabalhos relacionados a fim de entender melhor a discussão acadêmica atual, foram executadas duas buscas na base do google schollar utilizando com as definidas *strings*: 1) *("Mushroom"AND "UCI"AND "Schlimmer"AND "classification")* focada em trabalhos específicos sobre este *dataset* 2) *("mushroom classification"AND "machine learning"AND ("decision tree"OR "random forest"OR "neural networks") AND "performance analysis")* direcionada à classificação de performance preditiva, ambas retornando 241 e 78 resultados.

A partir desse montante, foram selecionados os cinco artigos de maior relevância para cada conjunto de busca, os quais somam à base teórica desta pesquisa.

Para a string 1): Para a string 1):

- Classification algorithm for edible mushroom identification - Wibowo et al. (2018) [Wibowo et al. 2018]
- Accuracy of classification poisonous or edible of mushroom using naive bayes and k-nearest neighbors - Hamonangan et al. (2021) [Hamonangan 2021]
- Ensemble learning based classification of edible and poisonous Agaricus mushrooms - Sahu et al. (2024) [Sahu et al. 2024]
- Mushroom Edibility Classification Using Analytical Attention Layers: A Methodological Study - Mukherjee, Dey e Mathur (2026) [Mathur et al. 2026]

- Performance comparison of mushroom types classification using K-nearest neighbor method and decision tree method - Chitayae e Sunyoto (2020) [Chitayae and Sunyoto 2020]

Para a string 2):

- Critical Analysis of Machine Learning and Deep Learning Models for Mushroom Classification [Neogi 2025]
- Optimizing mushroom classification through machine learning and hyperparameter tuning [Khasanah et al. 2024]
- Analysis of performance of classification algorithms in mushroom poisonous detection using confusion matrix analysis [Ortega et al. 2020]
- Automated mushroom species identification and prediction using image processing and machine learning [Gobinath et al. 2024]
- Performance analysis of decision tree algorithms on mushroom dataset [Lavanya and Preethi 2017]

Dos artigos selecionados de relevância da querry 1) que utilizaram esse dataset, o estudo conduzido por Wibowo et al. (2018) propõe uma análise comparativa de algoritmos de classificação para distinguir cogumelos venenosos e comestíveis das famílias *Agaricus* e *Lepiota* da mesma forma que o artigo vigente. Em contrapartida, a experimentação metodológica foi executada na ferramenta WEKA (software de código aberto amplamente utilizado para mineração de dados e aprendizado de máquina).

A pesquisa avaliou o desempenho de três arquiteturas computacionais: Árvore de Decisão, Naive Bayes e Máquinas de Vetores de Suporte (SVM). Obtendo resultados submetidos a validação cruzada [Geisser 1975], os dados mostraram que modelos de Árvore de decisão e SVM tiveram taxa preditiva máxima de 100%, enquanto em contraste, o algoritmo Naive Bayes registrou uma precisão de 95,82%. Desse modo, elegeram Árvore de decisão como o algorítimo superior por seu tempo de execução estatisticamente menor do que o algorítimo SVM.

Já o estudo de Hamonangan et al. (2021) direciona-se à otimização da precisão na classificação de cogumelos comestíveis e venenosos. Utilizando a mesma base de dados, a pesquisa realiza uma avaliação quantitativa, executando apenas dois algorítimos sobre o mesmo *dataset*. Onde Naive Bayes, empregando a biblioteca *GaussianNB*, alcançou uma acurácia inicial de 90,2% (matriz de confusão com 823 Verdadeiros Positivos e 643 Verdadeiros Negativos). Já o *KNN*, estabelecido como o algorítimo escolhido pela pesquisa, após ajuste do hiperparâmetro de vizinhos mais próximos para k=1, atingiu precisão de 100% sem o registro de Falsos Positivos ou Falsos Negativos (1.625 classificações corretas no teste).

O artigo conclui que o refinamento por aproximação KNN se demonstra categoricamente superior ao cálculo de probabilidades relativas *Naive Bayes* para a segmentação de segurança em *datasets* micológicos estruturados. Definindo o não consenso e a relevância do trabalho atual perante a escolha dos algorítimos.

Fomentando ainda mais a discussão sobre a escolha do algorítimo, Sahu et al. (2024) pesquisa sobre a aplicação de técnicas de aprendizado em conjunto para a categorização de segurança biológica de cogumelos *Agaricus* usando o mesmo *dataset*.

O diferencial fundamental deste trabalho é a substituição de classificadores singulares isolados pela integração de múltiplos modelos de predição. A avaliação comparativa testou cinco algoritmos baseados em ensemble: *Random Forest*, *Bagging*, *Gradient Boosting*, *AdaBoost* e *XGBoost*, aplicando validação cruzada também e encontrando os seguintes resultados que comprovaram a superioridade da abordagem: AdaBoost: Estabeleceu-se como a arquitetura mais eficiente, atingindo uma precisão preditiva de 95,35%. Gradient Boost: Atingiu 90,06%. XGBoost: Atingiu 88,51%. Bagging: Atingiu 85,79%. Random Forest: Atingiu 84,08%.

A conclusão do artigo confirma que a sinergia promovida pelas estratégias de ensemble, em especial o algoritmo AdaBoost, supera o desempenho de classificadores únicos prévios na literatura para a detecção de toxicidade em dados micológicos, trazendo um horizonte novo para as pesquisas do dataset.

O estudo conduzido por Mukherjee, Dey e Mathur (2026), mais próximo a data do trabalho atual, apresentou uma exploração metodológica mais focada na substituição de otimizações iterativas, como o gradiente descendente, por soluções analíticas de forma fechada na classificação dos cogumelos. Os autores destacam que o *dataset* em questão é linearmente separável após o devido pré-processamento.

Com os dados pré-processados, a arquitetura proposta calcula os pesos ótimos de projeção da atenção de maneira analítica, eliminando a estocasticidade e a necessidade de múltiplas gerações de treinamento para os modelos.

Em sua avaliação comparativa contra linhas de base iterativas, o modelo polinomial analítico obteve a acurácia máxima de 99,9%, enquanto a arquitetura de atenção analítica atingiu 99,41%. Desse modo, o estudo de Mukherjee, Dey e Mathur (2026) estabelece que os métodos analíticos testados alcançam o estado da arte em precisão. fornecendo duas vantagens arquitetônicas estruturais: a garantia de reprodutibilidade determinística (gerando resultados idênticos a cada execução) e uma eficiência computacional superior. Além disso, a extração direta dos pesos do modelo corroborou evidências biológicas anteriores, identificando o atributo ”odor”como a variável de maior impacto preditivo na determinação da toxicidade.

E por último sobre trabalhos do mesmo dataset, a pesquisa de Chitayae e Sunyoto (2020) conduz uma comparação direta entre dois métodos, KNN e Árvore de Decisão (Algoritmo CART). No seu pré-processamento, para conversão de variáveis nominais e tratamento de dados ausentes (remoção de instâncias vazias no atributo ”Stalk Root”). O estudo aplicou a técnica de filtro por Matriz de Correlação (Heatmap) para selecionar os oito atributos de maior impacto preditivo, a fim de avaliar os modelos utilizando validação cruzada também. Os resultados dos dois classificadores demonstrou que o KNN após sucessivos testes, alcançou sua performance otimizada com o hiperparâmetro k=11. Seu resultado de acurácia máxima foi de 89,61%. E na Árvore de Decisão (Algoritmo CART) sob o mesmo crivo da validação cruzada, foi superior, atingindo uma acurácia de 91,93%, tendo um F1-Score de 92,10% e uma precisão de 92,27%. A conclusão do artigo confirma a superioridade arquitetônica do algoritmo CART sobre a técnica de KNN para a categorização específica do dataset. Entregando métricas de precisão mais robustas na distinção de cogumelos venenosos.

No âmbito dos trabalhos direcionados à classificação de performance preditiva, a

literatura divide-se em duas abordagens metodológicas principais: modelos baseados em dados estruturados (tabulares) e modelos de visão computacional baseados em imagens.

Em contraste, a pesquisa *Critical Analysis of Machine Learning and Deep Learning Models* avaliou um *dataset* reduzido e curado de apenas 326 imagens. O estudo testou algoritmos clássicos como Random Forest contra arquiteturas de Deep Learning (ResNet, VGG16, MobileNetV2). O modelo MobileNetV2 apresentou o maior desempenho (82,14%), contudo, ao comparar esses resultados com a literatura focada na base UCI, nota-se uma eficiência preditiva inferior. Essa queda de métrica é uma consequência arquitetônica direta da aplicação de redes neurais profundas em *datasets* fotográficos escassos, limitando a capacidade de generalização do modelo frente às abordagens tabulares.

Focando no processamento de dados estruturados e utilizando a base de dados pública da UCI, o estudo *Analysis of Performance of Classification Algorithms in Mushroom Poisonous Detection* aplicou a metodologia KDD (*Knowledge Discovery in Databases*) para extrair padrões de atributos físicos. A pesquisa avaliou quatro algoritmos e concluiu que a Árvore de Decisão obteve o maior desempenho (88,2% de acurácia), superando o KNN, Regressão Logística e Naïve Bayes. Corroborando com a eficácia desse modelo, a pesquisa de Wibowo et al. (2018) estruturou uma comparação entre C4.5 (Árvore de Decisão), Naïve Bayes e SVM na mesma base de dados. A validação empírica demonstrou que a Árvore de Decisão e o SVM obtiveram o desempenho máximo (100% de acurácia), mas o modelo em árvore estabeleceu superioridade por exigir menor tempo de processamento e otimizar a dimensionalidade do problema de 22 para apenas cinco atributos.

Ainda sob o paradigma de dados tabulares da UCI, o confronto direto estabelecido em *Performance Comparison of Mushroom Types Classification Using K-Nearest Neighbor Method and Decision Tree Method* confirmou a vantagem da Árvore de Decisão (91,93%) sobre o modelo KNN (89,61%) sob validação cruzada. Contudo, o estudo de Hamonangan et al. (2021) demonstrou que otimizações paramétricas no KNN (ajuste para $k = 1$) podem elevar a acurácia para 100%, superando amplamente o Naïve Bayes (90,2%) . Tais modelos singulares têm sido progressivamente substituídos por arquiteturas integradas, como demonstrado na aplicação de *Ensemble Learning*, onde o modelo AdaBoost alcançou 95,35% de acurácia , ou pela substituição de otimizações iterativas por camadas de atenção analítica e modelos polinomiais, capazes de atingir até 99,9% de precisão de forma determinística.

Por outro lado, avançando para o paradigma de Visão Computacional, a classificação preditiva enfrenta o desafio da extração de características não-estruturadas. O estudo *Automated Mushroom Species Identification and Prediction Using Image Processing and Machine Learning* propôs um sistema de Redes Neurais Convolucionais (CNN) aplicado a um *dataset* de 1.000 imagens. A pesquisa evidenciou que a utilização rigorosa de técnicas de pré-processamento (como detecção de bordas e análise de textura) contribui significativamente para o modelo, permitindo que a CNN atingisse 94,5% de acurácia.

3. Metodologia

O fluxo metodológico deste estudo baseou-se em treinar, ajustar hiperparâmetros e validar seis diferentes famílias de algoritmos classificadores, avaliando suas performances num

cenário em que falsos negativos podem significar fatalidades.

3.1. A Métrica de Revocação (Recall)

Em problemas de classificação binária padrão, a Acurácia (taxa geral de acertos) costuma ser a métrica guia. Contudo, o domínio deste estudo exige uma abordagem assimétrica, já que os tipos de erro que o modelo pode cometer tem pesos e consequências completamente diferentes. Classificar um cogumelo comestível como venenoso (Falso Positivo) resulta apenas na perda de uma fonte de alimento. Em contrapartida, prever que um espécime tóxico é inofensivo e comestível (Falso Negativo) pode resultar em fatalidades.

Por esse motivo, o *Recall* (Revocação) focado na classe 1 (Venenoso) foi eleito como a métrica soberana, expressando a capacidade do modelo de encontrar todas as instâncias positivas do *dataset*. O desempenho dos modelos foi complementado pela análise Curva *Precision-Recall* (PR), que é particularmente informativa ao lidar com as trocas matemáticas (*trade-offs*) entre não deixar falsos negativos passarem (alta Revocação e não emitir alarmes falsos excessivos (alta Precisao).

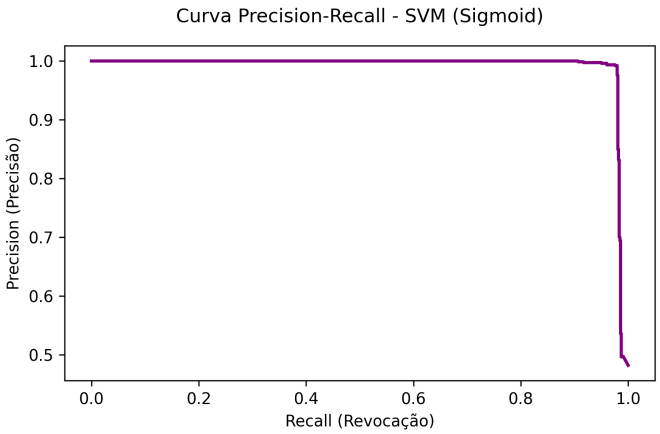

Figura 2. Curva Precision-Recall destacando o trade-off entre as métricas para a classe Venenosa.

A Figura 2 ilustra a Curva Precision-Recall obtida pelo modelo SVM com kernel Sigmoid. Observa-se que, para a vasta maioria dos limiares de decisão, o modelo sustenta Precisão igual a 1,0 com Revocação próxima de zero até aproximadamente 0,90, indicando que, nessa faixa, toda instância classificada como Venenosa é de fato venenosa. O comportamento crítico ocorre na região da alta Revocação (acima de 0,90): ao forçar o modelo a recuperar quase a totalidade dos espécimes tóxicos, a Precisão sofre uma queda abrupta, chegando a aproximadamente 0,50 no limiar de Revocação máxima. Esse *trade-off* revela que, para o domínio deste estudo, operar com limiares que privilegiem Revocação $\geq$ 0,95 implica aceitar um aumento considerável de Falsos Positivos, que seriam cogumelos comestíveis descartados por precaução, consequência essa amplamente preferível à alternativa de permitir que espécimes venenosos passem despercebidos.

3.2. Algoritmos Analisados

Foram selecionados seis métodos clássicos de aprendizado supervisionado, englobando diferentes paradigmas teóricos:

- **K-Nearest Neighbours (KNN):** Algoritmo basedo em distância geométrica, classificado como *lazy learner*. Foi avaliado com a distância Euclidiana, iterando sobre diferentes valores de K para balancear o sobreajuste e a suavidade da fronteira de decisão.
- **Naive Bayes:** Modelo probabilístico fundamentado no Teorema de Bayes, assumindo ingenuamente a independência entre as variáveis. Dadas as colunas binárias geradas pelo *One-Hot Encoding*, distribuições específicas como Bernoulli e Complement foram priorizadas na investigação.
- **Árvores de Decisão (*Decision Trees*):** Estruturas de particionamento baseadas em regras de ganho de informação (Entropia e Índice Gini). Por possuírem alta explicabilidade teórica, facilitam a extração de regras para identificar as características biológicas mais críticas.
- **Random Forest:** Algoritmo *Ensemble* que constrói múltiplas árvores de decisão descorrelacionadas via *bagging*. Busca mitigar o *overfitting* crônico das árvores simples, estabilizando as predições.
- **Support Vector Machines (SVM):** Modelo desenhado para encontrar o hiperplano de margem máxima que separa as classes. Diferentes funções de mapeamento (*Kernels*), como Linear e RBF (Radial Basis Function), foram testados para contornar a não-linearidade dos dados.
- **Redes Neurais Artificiais (MLP):** Arquiteturas *Multi-Layer Perceptron* baseadas em retropropagação (*backpropagation*). Foram exploradas variações na quantidade de camadas ocultas e diferentes otimizadores matemáticos (Adam e L-BFGS) para avaliar a extração de padrões complexos.

A validação da generalização dos modelos foi conduzida através da Validação Cruzada Estratificada (*Stratified K-Fold*) com 5 divisões, assegurando que a proporção das classes alvo se mantivesse constante em todos os subconjuntos e eliminando o viés inerente a uma única divisão de particionamento estático treino/teste.

4. Obtenção e preparação dos dados

Devido à natureza dos algoritmos de aprendizado de máquina, que exigem entradas numéricas, o pré-processamento exigiu transformações rigorosas. Em primeiro momento, a variável alvo foi binarizada mapeando-se a classe perigosa como 1 (*poisonous*) e a comestível como 0, alinhando-se ao objetivo de detecção de risco.

Para as 22 variáveis preditoras independentes, aplicou-se a técnica de *One-Hot Encoding*. A fim de evitar a multicolinearidade induzida, a qual ocorre quando uma variável pode ser escrita como uma combinação linear exata de outras, o primeiro nível de cada categoria foi removido (*drop_first=True*), garantindo a independência linear das *features* resultantes.

Para algoritmos sensíveis ao cálculo de distâncias em espaços multidimensionais (como KNN, SVM e Redes Neurais), os dados sofreram padronização (*Z-score normalization*), onde cada atributo foi reescalonado para possuir média zero e desvio padrão igual a um. Importante ressaltar que o aprendizado dessa escala foi rigorosamente isolado: o cálculo da média e do desvio padrão foi extraído exclusivamente dos dados de treinamento. Essa regra foi então aplicada aos dados de teste sem recalcular seus parâmetros internos, garantindo que o modelo não tivesse acesso prévio a informações do conjunto de avaliação (*data leakage*).

Tabela 1. Descrição e classificação dos atributos do dataset Mushroom.

Atributo	Descrição	Valores Possíveis	Tipo de Dado
class	Variável Alvo	e=comestível, p=venenoso	Qualit. Nominal (Binária)
cap-shape	Formato do chapéu	b=sino, c=cônico, x=convexo, f=plano, k=nodoso, s=afundado	Qualit. Nominal
cap-surface	Superfície do chapéu	f=fibrosa, g=ranhuras, y=escamosa, s=lisa	Qualit. Nominal
cap-color	Cor do chapéu	n=marrom, b=creme, c=canela, g=cinza, r=verde, p=rosa, u=roxo, e=vermelho, w=branco, y=amarelo	Qualit. Nominal
bruises	Hematomas	t=tem hematomas, f=não tem	Qualit. Nominal (Binária)
odor	Cheiro	a=amêndoa, l=anis, c=creosoto, y=peixe, f=pútrido, m=mofo, n=nenhum, p=pungente, s=picante	Qualit. Nominal
gill-attachment	Ligação das lamelas	a=anexada, d=descendente, f=livre, n=entalhada	Qualit. Nominal
gill-spacing	Espaçamento (lamelas)	c=próximas, w=aglomeradas, d=distantes	Qualit. Ordinal
gill-size	Tamanho das lamelas	b=larga, n=estreita	Qualit. Nominal (Binária)
stalk-root	Raiz do talo	b=bulbosa, c=clava, u=taça, e=igual, z=rizomorfos, r=enraizada, ?=ausente	Qualit. Nominal
spore-print-color	Cor dos esporos	k=preto, n=marrom, b=creme, h=chocolate, r=verde, o=laranja, u=roxo, w=branco, y=amarelo	Qualit. Nominal
population	População	a=abundante, c=agrupada, n=numerosa, s=espalhada, v=várias, y=solitária	Qualit. Ordinal
habitat	Habitat	g=gramíneas, l=folhas, m=prados, p=caminhos, u=urbano, w=desperdício, d=bosques	Qualit. Nominal

Nota: Foram omitidos alguns atributos de cor e superfície do talo/véu por brevidade, mas todos seguem o padrão qualitativo nominal.

5. Resultados e Discussões

6. Conclusões

Referências

Breiman, L. (2001). Random forests. *Machine learning*, 45(1):5–32.

Bruce, P. and Bruce, A. (2017). *Practical Statistics for Data Scientists: 50 Essential Concepts*. O'Reilly Media.

Chitayae, N. and Sunyoto, A. (2020). Performance comparison of mushroom types classification using k-nearest neighbor method and decision tree method. In *2020 3rd international conference on information and communications technology (ICOIACT)*, pages 308–313. IEEE.

Cover, T. (1968). Nearest neighbor pattern classification. *IEEE Trans. Information Theory*, 4(5):515–516.

Geisser, S. (1975). The predictive sample reuse method with applications. *Journal of the American statistical Association*, 70(350):320–328.

Gobinath, A., Rajeswari, P., Anandan, M., et al. (2024). Automated mushroom species identification and prediction using image processing and machine learning. In *2024 International BIT Conference (BITCON)*, pages 1–5. IEEE.

Hamonangan, R. (2021). Accuracy of classification poisonous or edible of mushroom using naïve bayes and k-nearest neighbors. *Journal of Soft Computing Exploration*.

Hand, D. J. and Yu, K. (2001). Idiot's bayes—not so stupid after all? *International statistical review*, 69(3):385–398.

Khasanah, H. M., Aminuddin, A., Abdulloh, F. F., Rahardi, M., Hairani, H., and Asaddulloh, B. P. (2024). Optimizing mushroom classification through machine learning and hyperparameter tuning. *Engineering and Applied Science Research*, 51(5):651–660.

Lavanya, B. and Preethi, G. (2017). Performance analysis of decision tree algorithms on mushroom dataset. *International Journal for Research in Applied Science and Engineering Technology*, 5(11):183–191.

Mathur, A., Mukherjee, A., and Dey, S. (2026). Mushroom edibility classification using analytical attention layers: A methodological study.

Neogi, A. (2025). *Critical Analysis of Machine Learning and Deep Learning Models for Mushroom Classification*. PhD thesis, Dublin, National College of Ireland.

Ortega, J., Lagman, A. C., Natividad, L. R. Q., Bantug, E. T., Resureccion, M. R., and Manalo, L. (2020). Analysis of performance of classification algorithms in mushroom poisonous detection using confusion matrix analysis. *International Journal*, 9(1.3).

Quinlan, J. R. (1986). Induction of decision trees. *Machine learning*, 1(1):81–106.

Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1986). Learning representations by back-propagating errors. *nature*, 323(6088):533–536.

Sahu, R., Pandey, S., Verma, R., and Pandey, P. (2024). Ensemble learning based classification of edible and poisonous agaricus mushrooms. In *2024 Fourth International Conference on Advances in Electrical, Computing, Communication and Sustainable Technologies (ICAECT)*, pages 1–7. IEEE.

Schlimmer, J. (1987). Mushroom classification: Edible or poisonous? Kaggle. Dataset extraído do UCI Machine Learning Repository.

Van Rijsbergen, C. J. (1986). A non-classical logic for information retrieval. *The computer journal*, 29(6):481–485.

Vapnik, V. (1995). Support-vector networks. *Machine learning*, 20:273–297.

Wibowo, A., Rahayu, Y., Riyanto, A., and Hidayatulloh, T. (2018). Classification algorithm for edible mushroom identification. In *2018 International Conference on Information and Communications Technology (ICOIACT)*, pages 250–253. IEEE.