Risco Biológico e Aprendizado de Máquina: Otimização de Falsos Negativos na Classificação de Cogumelos *Agaricus* e *Lepiota*

Kauã Alves Santos[1], **Mateus Vinicius Zebendo Pinto**[1,2]

[1]Centro Federal de Educação Tecnológica Celso Suckow da Fonseca – CEFET/RJ
Campus Nova Friburgo – Nova Friburgo, RJ – Brasil

13504982705@cefet-rj.com.br, 15674748705@cefet-rj.com.br

Resumo. *A ingestão acidental de cogumelos venenosos representa um risco biológico letal, exigindo rigor metodológico na automação de sua identificação. Este estudo avalia o desempenho de seis algoritmos de Aprendizado de Máquina (KNN, Naive Bayes, Árvore de Decisão, Random Forest, SVM e Redes Neurais) na classificação de 8.124 espécimes das famílias Agaricus e Lepiota. Rompendo com o paradigma da acurácia global, a pesquisa estabelece a Revocação (Recall) da classe tóxica como métrica soberana, penalizando severamente os Falsos Negativos. A metodologia incluiu rigoroso pré-processamento, com imputação semântica de valores ausentes e prevenção de multicolinearidade, validado por Stratified 5-Fold Cross-Validation. Os resultados demonstraram que modelos probabilísticos e de margens não-lineares falharam na contenção de risco. A Árvore de Decisão atingiu desempenho ótimo absoluto (*$1,0000 \pm 0,0000$ *em Revocação), isolando-se como a arquitetura ideal pelo Princípio da Parcimônia. Além de garantir segurança biológica irrestrita com baixo custo computacional, o modelo forneceu alta explicabilidade teórica, confirmando o atributo "Odor" como o vetor primário de toxicidade.* ***Palavras-chave:*** *Aprendizado de Máquina. Aprendizado Supervisionado. Árvores de Decisão. Segurança Biológica. Revocação.*

1. Introdução

O artigo avalia algoritmos de aprendizado de máquina para a criação de um modelo de classificação supervisionada. O objetivo central é encontrar o algoritmos, entre os seis analisados, que minimize falsos negativos e priorize a Revocação [Van Rijsbergen 1986] sobre a acurácia bruta para a base em questão, a fim de diminuir a ingestão acidental ou equivocada de cogumelos *Agaricus* e *Lepiota*.

A base de dados em questão (dataset) utilizada nesse artigo foi a mushroom-classification [Schlimmer 1987]. Esse dataset, criado por Jeffrey Schlimmer em 1987, contém 8.124 registros de cogumelos gilled das famílias *Agaricus* e *Lepiota*. O termo *gilled* refere-se às lamelas de um cogumelo como mostrado na figura 1 e explicado na Seção 1.1.

Trabalho desenvolvido como requisito de avaliação da disciplina optativa de Técnicas de Aprendizado de Máquina (2026.1) do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca (CEFET/RJ) - Campus Nova Friburgo. O referencial metodológico para a concepção dos modelos baseou-se em Bruce [Bruce and Bruce 2017].

O desafio fundamental do artigo é a classificação binária de espécimes em comestível ou venenoso, onde o grande gafe de predição ocorre quando uma espécie tóxica é classificada como comestível (Falso negativo). Esse risco biológico estabelece a Revocação (Recall) como a métrica determinante para a avaliação da melhor técnica de aprendizado de máquina para esse dataset. Para esse intuito, foram feitas análises de seis algoritmos:

- 1. K-Nearest Neighbours (KNN) [Cover 1968]
- 2. Naive Bayes [Hand and Yu 2001]
- 3. Decision Three (Árvore de decisão) [Quinlan 1986]
- 4. Random Forest [Breiman 2001]
- 5. Support Vector Machines (SVM) [Vapnik 1995] e
- 6. Redes Neurais [Rumelhart et al. 1986]

A avaliação comparativa desses seis algorítimos visa determinar não apenas o modelo com menor taxa de erro, mas aquele que oferece a maior estabilidade e adequação ao rigor exigido pelo contexto de segurança biológica.

1.1. Biologia dos cogumelos

A família *Agaricus* compreende alguns dos fungos mais difundidos, incluindo o cogumelo de Paris ou Champignon (*Agaricus bisporus*). Morfologicamente, espécimes desta família caracterizam-se por apresentarem lamelas livres em relação ao estipe e esporos com coloração variando entre marrom-escuro e chocolate, características que fundamentam importantes atributos preditivos no dataset estudado.

Já a família *Lepiota* assume papel central na análise de segurança biológica e na métrica de Revocação deste estudo. O risco crítico de classificação reside na alta toxicidade de diversas espécies deste grupo, que contêm *amatoxinas* — octapeptídeos cíclicos responsáveis pela maioria dos envenenamentos fatais por fungos. Esta família apresenta frequentemente escamas no píleo (chapéu) e anel no estipe, características essas que se revelaram fundamentais para a distinção lógica da toxicidade.

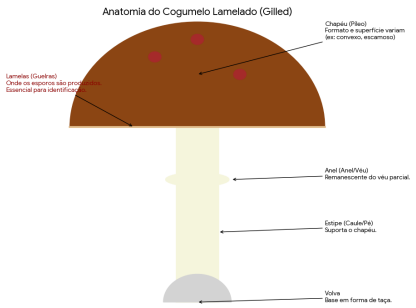

Figura 1. Anatomia de um cogumelo lamelado e suas partes principais.

2. Trabalhos Relacionados

Para a revisão de trabalhos relacionados a fim de entender melhor a discussão acadêmica atual, foram executadas duas buscas na base do google schollar utilizando com as definidas *strings*: 1) *("Mushroom"AND "UCI"AND "Schlimmer"AND "classification")* focada em trabalhos específicos sobre este *dataset* 2) *("mushroom classification"AND*

”machine learning”AND (”decision tree”OR ”random forest”OR ”neural networks”) AND ”performance analysis”) direcionada à classificação de performance preditiva, ambas retornando 241 e 78 resultados.

A partir desse montante, foram selecionados os cinco artigos de maior relevância para cada conjunto de busca, os quais somam à base teórica desta pesquisa.

Para a string 1): Para a string 1):

- Classification algorithm for edible mushroom identification - Wibowo et al. (2018) [Wibowo et al. 2018]
- Accuracy of classification poisonous or edible of mushroom using naive bayes and k-nearest neighbors - Hamonangan et al. (2021) [Hamonangan 2021]
- Ensemble learning based classification of edible and poisonous Agaricus mushrooms - Sahu et al. (2024) [Sahu et al. 2024]
- Mushroom Edibility Classification Using Analytical Attention Layers: A Methodological Study - Mukherjee, Dey e Mathur (2026) [Mathur et al. 2026]
- Performance comparison of mushroom types classification using K-nearest neighbor method and decision tree method - Chitayae e Sunyoto (2020) [Chitayae and Sunyoto 2020]

Para a string 2):

- Critical Analysis of Machine Learning and Deep Learning Models for Mushroom Classification [Neogi 2025]
- Optimizing mushroom classification through machine learning and hyperparameter tuning [Khasanah et al. 2024]
- Analysis of performance of classification algorithms in mushroom poisonous detection using confusion matrix analysis [Ortega et al. 2020]
- Automated mushroom species identification and prediction using image processing and machine learning [Gobinath et al. 2024]
- Performance analysis of decision tree algorithms on mushroom dataset [Lavanya and Preethi 2017]

Dos artigos selecionados de relevância da querry 1) que utilizaram esse dataset, o estudo conduzido por Wibowo et al. (2018) propõe uma análise comparativa de algoritmos de classificação para distinguir cogumelos venenosos e comestíveis das famílias *Agaricus* e *Lepiota* da mesma forma que o artigo vigente. Em contrapartida, a experimentação metodológica foi executada na ferramenta WEKA (software de código aberto amplamente utilizado para mineração de dados e aprendizado de máquina).

A pesquisa avaliou o desempenho de três arquiteturas computacionais: Árvore de Decisão, Naive Bayes e Máquinas de Vetores de Suporte (SVM). Obtendo resultados submetidos a validação cruzada [Geisser 1975], os dados mostraram que modelos de Árvore de decisão e SVM tiveram taxa preditiva máxima de 100%, enquanto em contraste, o algoritmo Naive Bayes registrou uma precisão de 95,82%. Desse modo, elegeram Árvore de decisão como o algorítimo superior por seu tempo de execução estatisticamente menor do que o algorítimo SVM.

Já o estudo de Hamonangan et al. (2021) direciona-se à otimização da precisão na classificação de cogumelos comestíveis e venenosos. Utilizando a mesma base de dados,

a pesquisa realiza uma avaliação quantitativa, executando apenas dois algorítimos sobre o mesmo *dataset*. Onde Naive Bayes, empregando a biblioteca *GaussianNB*, alcançou uma acurácia inicial de 90,2% (matriz de confusão com 823 Verdadeiros Positivos e 643 Verdadeiros Negativos). Já o *KNN*, estabelecido como o algorítimo escolhido pela pesquisa, após ajuste do hiperparâmetro de vizinhos mais próximos para k=1, atingiu precisão de 100% sem o registro de Falsos Positivos ou Falsos Negativos (1.625 classificações corretas no teste).

O artigo conclui que o refinamento por aproximação KNN se demonstra categoricamente superior ao cálculo de probabilidades relativas *Naive Bayes* para a segmentação de segurança em *datasets* micológicos estruturados. Definindo o não consenso e a relevância do trabalho atual perante a escolha dos algorítimos.

Fomentando ainda mais a discussão sobre a escolha do algorítimo, Sahu et al. (2024) pesquisa sobre a aplicação de técnicas de aprendizado em conjunto para a categorização de segurança biológica de cogumelos *Agaricus* usando o mesmo *dataset*.

O diferencial fundamental deste trabalho é a substituição de classificadores singulares isolados pela integração de múltiplos modelos de predição. A avaliação comparativa testou cinco algoritmos baseados em ensemble: *Random Forest*, *Bagging*, *Gradient Boosting*, *AdaBoost* e *XGBoost*, aplicando validação cruzada também e encontrando os seguintes resultados que comprovaram a superioridade da abordagem: AdaBoost: Estabeleceu-se como a arquitetura mais eficiente, atingindo uma precisão preditiva de 95,35%. Gradient Boost: Atingiu 90,06%. XGBoost: Atingiu 88,51%. Bagging: Atingiu 85,79%. Random Forest: Atingiu 84,08%.

A conclusão do artigo confirma que a sinergia promovida pelas estratégias de ensemble, em especial o algoritmo AdaBoost, supera o desempenho de classificadores únicos prévios na literatura para a detecção de toxicidade em dados micológicos, trazendo um horizonte novo para as pesquisas do dataset.

O estudo conduzido por Mukherjee, Dey e Mathur (2026), mais próximo a data do trabalho atual, apresentou uma exploração metodológica mais focada na substituição de otimizações iterativas, como o gradiente descendente, por soluções analíticas de forma fechada na classificação dos cogumelos. Os autores destacam que o *dataset* em questão é linearmente separável após o devido pré-processamento.

Com os dados pré-processados, a arquitetura proposta calcula os pesos ótimos de projeção da atenção de maneira analítica, eliminando a estocasticidade e a necessidade de múltiplas gerações de treinamento para os modelos.

Em sua avaliação comparativa contra linhas de base iterativas, o modelo polinomial analítico obteve a acurácia máxima de 99,9%, enquanto a arquitetura de atenção analítica atingiu 99,41%. Desse modo, o estudo de Mukherjee, Dey e Mathur (2026) estabelece que os métodos analíticos testados alcançam o estado da arte em precisão. fornecendo duas vantagens arquitetônicas estruturais: a garantia de reprodutibilidade determinística (gerando resultados idênticos a cada execução) e uma eficiência computacional superior. Além disso, a extração direta dos pesos do modelo corroborou evidências biológicas anteriores, identificando o atributo ”odor”como a variável de maior impacto preditivo na determinação da toxicidade.

E por último sobre trabalhos do mesmo dataset, a pesquisa de Chitayae e Sunyoto (2020) conduz uma comparação direta entre dois métodos, KNN e Árvore de Decisão (Algoritmo CART). No seu pré-processamento, para conversão de variáveis nominais e tratamento de dados ausentes (remoção de instâncias vazias no atributo ”Stalk Root”). O estudo aplicou a técnica de filtro por Matriz de Correlação (Heatmap) para selecionar os oito atributos de maior impacto preditivo, a fim de avaliar os modelos utilizando validação cruzada também. Os resultados dos dois classificadores demonstrou que o KNN após sucessivos testes, alcançou sua performance otimizada com o hiperparâmetro k=11. Seu resultado de acurácia máxima foi de 89,61%. E na Árvore de Decisão (Algoritmo CART) sob o mesmo crivo da validação cruzada, foi superior, atingindo uma acurácia de 91,93%, tendo um F1-Score de 92,10% e uma precisão de 92,27%. A conclusão do artigo confirma a superioridade arquitetônica do algoritmo CART sobre a técnica de KNN para a categorização específica do dataset. Entregando métricas de precisão mais robustas na distinção de cogumelos venenosos.

No âmbito dos trabalhos direcionados à classificação de performance preditiva, a literatura divide-se em duas abordagens metodológicas principais: modelos baseados em dados estruturados (tabulares) e modelos de visão computacional baseados em imagens.

Em contraste, a pesquisa *Critical Analysis of Machine Learning and Deep Learning Models* avaliou um *dataset* reduzido e curado de apenas 326 imagens. O estudo testou algoritmos clássicos como Random Forest contra arquiteturas de Deep Learning (ResNet, VGG16, MobileNetV2). O modelo MobileNetV2 apresentou o maior desempenho (82,14%), contudo, ao comparar esses resultados com a literatura focada na base UCI, nota-se uma eficiência preditiva inferior. Essa queda de métrica é uma consequência arquitetônica direta da aplicação de redes neurais profundas em *datasets* fotográficos escassos, limitando a capacidade de generalização do modelo frente às abordagens tabulares.

Focando no processamento de dados estruturados e utilizando a base de dados pública da UCI, o estudo *Analysis of Performance of Classification Algorithms in Mushroom Poisonous Detection* aplicou a metodologia KDD (*Knowledge Discovery in Databases*) para extrair padrões de atributos físicos. A pesquisa avaliou quatro algoritmos e concluiu que a Árvore de Decisão obteve o maior desempenho (88,2% de acurácia), superando o KNN, Regressão Logística e Naïve Bayes. Corroborando com a eficácia desse modelo, a pesquisa de Wibowo et al. (2018) estruturou uma comparação entre C4.5 (Árvore de Decisão), Naïve Bayes e SVM na mesma base de dados. A validação empírica demonstrou que a Árvore de Decisão e o SVM obtiveram o desempenho máximo (100% de acurácia), mas o modelo em árvore estabeleceu superioridade por exigir menor tempo de processamento e otimizar a dimensionalidade do problema de 22 para apenas cinco atributos.

Ainda sob o paradigma de dados tabulares da UCI, o confronto direto estabelecido em *Performance Comparison of Mushroom Types Classification Using K-Nearest Neighbor Method and Decision Tree Method* confirmou a vantagem da Árvore de Decisão (91,93%) sobre o modelo KNN (89,61%) sob validação cruzada. Contudo, o estudo de Hamonangan et al. (2021) demonstrou que otimizações paramétricas no KNN (ajuste para $k = 1$) podem elevar a acurácia para 100%, superando amplamente o Naïve Bayes (90,2%) . Tais modelos singulares têm sido progressivamente substituídos por arquite-

turas integradas, como demonstrado na aplicação de *Ensemble Learning*, onde o modelo AdaBoost alcançou 95,35% de acurácia , ou pela substituição de otimizações iterativas por camadas de atenção analítica e modelos polinomiais, capazes de atingir até 99,9% de precisão de forma determinística.

Por outro lado, avançando para o paradigma de Visão Computacional, a classificação preditiva enfrenta o desafio da extração de características não-estruturadas. O estudo *Automated Mushroom Species Identification and Prediction Using Image Processing and Machine Learning* propôs um sistema de Redes Neurais Convolucionais (CNN) aplicado a um *dataset* de 1.000 imagens. A pesquisa evidenciou que a utilização rigorosa de técnicas de pré-processamento (como detecção de bordas e análise de textura) contribui significativamente para o modelo, permitindo que a CNN atingisse 94,5% de acurácia.

3. Metodologia

O fluxo metodológico deste estudo baseou-se em treinar, ajustar hiperparâmetros e validar seis diferentes famílias de algoritmos classificadores, avaliando suas performances num cenário em que falsos negativos podem significar fatalidades.

3.1. A Métrica de Revocação (Recall)

Em problemas de classificação binária padrão, a Acurácia (taxa geral de acertos) costuma ser a métrica guia. Contudo, o domínio deste estudo exige uma abordagem assimétrica, já que os tipos de erro que o modelo pode cometer tem pesos e consequências completamente diferentes. Classificar um cogumelo comestível como venenoso (Falso Positivo) resulta apenas na perda de uma fonte de alimento. Em contrapartida, prever que um espécime tóxico é inofensivo e comestível (Falso Negativo) pode resultar em fatalidades.

Por esse motivo, o *Recall* (Revocação) focado na classe 1 (Venenoso) foi eleito como a métrica soberana, expressando a capacidade do modelo de encontrar todas as instâncias positivas do *dataset*. O desempenho dos modelos foi complementado pela análise Curva *Precision-Recall* (PR), que é particularmente informativa ao lidar com as trocas matemáticas (*trade-offs*) entre não deixar falsos negativos passarem (alta Revocação e não emitir alarmes falsos excessivos (alta Precisao).

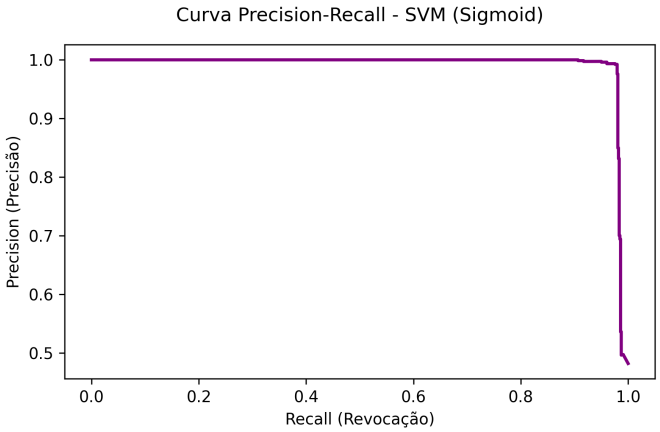

Figura 2. Curva Precision-Recall destacando o trade-off entre as métricas para a classe Venenosa.

Reprodutibilidade em `https://github.com/mateuszebendo/tecnicas-de-machine-learning.git`

A Figura 2 ilustra a Curva Precision-Recall obtida pelo modelo SVM com kernel Sigmoid. Observa-se que, para a vasta maioria dos limiares de decisão, o modelo sustenta Precisão igual a 1,0 com Revocação próxima de zero até aproximadamente 0,90, indicando que, nessa faixa, toda instância classificada como Venenosa é de fato venenosa. O comportamento crítico ocorre na região da alta Revocação (acima de 0,90): ao forçar o modelo a recuperar quase a totalidade dos espécimes tóxicos, a Precisão sofre uma queda abrupta, chegando a aproximadamente 0,50 no limiar de Revocação máxima. Esse *trade-off* revela que, para o domínio deste estudo, operar com limiares que privilegiem Revocação $\geq$ 0,95 implica aceitar um aumento considerável de Falsos Positivos, que seriam cogumelos comestíveis descartados por precaução, consequência essa amplamente preferível à alternativa de permitir que espécimes venenosos passem despercebidos.

3.2. Algoritmos Analisados

Foram selecionados seis métodos clássicos de aprendizado supervisionado, englobando diferentes paradigmas teóricos:

- **K-Nearest Neighbours (KNN):** Algoritmo basedo em distância geométrica, classificado como *lazy learner*. Foi avaliado com a distância Euclidiana, iterando sobre diferentes valores de K para balancear o sobreajuste e a suavidade da fronteira de decisão.
- **Naive Bayes:** Modelo probabilístico fundamentado no Teorema de Bayes, assumindo ingenuamente a independência entre as variáveis. Dadas as colunas binárias geradas pelo *One-Hot Encoding*, distribuições específicas como Bernoulli e Complement foram priorizadas na investigação.
- **Árvores de Decisão (*Decision Trees*):** Estruturas de particionamento baseadas em regras de ganho de informação (Entropia e Índice Gini). Por possuírem alta explicabilidade teórica, facilitam a extração de regras para identificar as características biológicas mais críticas.
- **Random Forest:** Algoritmo *Ensemble* que constrói múltiplas árvores de decisão descorrelacionadas via *bagging*. Busca mitigar o *overfitting* crônico das árvores simples, estabilizando as predições.
- **Support Vector Machines (SVM):** Modelo desenhado para encontrar o hiperplano de margem máxima que separa as classes. Diferentes funções de mapeamento (*Kernels*), como Linear e RBF (Radial Basis Function), foram testados para contornar a não-linearidade dos dados.
- **Redes Neurais Artificiais (MLP):** Arquiteturas *Multi-Layer Perceptron* baseadas em retropropagação (*backpropagation*). Foram exploradas variações na quantidade de camadas ocultas e diferentes otimizadores matemáticos (Adam e L-BFGS) para avaliar a extração de padrões complexos.

A validação da generalização dos modelos foi conduzida através da Validação Cruzada Estratificada (*Stratified K-Fold*) com 5 divisões, assegurando que a proporção das classes alvo se mantivesse constante em todos os subconjuntos e eliminando o viés inerente a uma única divisão de particionamento estático treino/teste.

Toda a experimentação, pré-processamento e avaliação dos resultados foram desenvolvidos usando Python e a biblioteca Scikit-Learn. A otimização dos hiperparâmetros dos algorítimos foi conduzido através de uma busca exaustiva em grade (GridSearchCV)

[Pedregosa et al. 2011], para a máximização da métrica de revocação. Para garantir reprodutibilidade dos cortes da validação cruzada do processo e inicialização baseada em probabilidade, fixou-se uma semente aleatória global em todos os processos.

4. Obtenção e preparação dos dados

Após a identificação das variáveis, identificou-se que a variável `stalk-root` apresentava valores ausentes que retornavam '?'. De forma a preservar esses dados, optou-se por definir-los em categoria explicita "desconhecido". Assim, a abordagem permite os determinados algorítimos interpretarem a ausência da informação como uma característica do fungo.

Sequencialmente, a variável alvo *class* foi transformada em um Label Encoding [Pedregosa et al. 2011]. Contendo duas classes: *edible* (comestível, representada por 'e') e *poisonous* (venenoso, representada por 'p'), a adequação da saída foi mapeada em binário, definindo 1 para instâncias venenosas e o valor 0 para instâncias comestíveis.

Dessa forma, foi aplicada a função *get_dummies* do Pandas, fazendo a remoção da primeira categoria de cada variável transformada, para evitar *dummy variable trap* [James et al. 2013] e garantindo a independência linear. Desse modo, a dimensionalidade do *dataset* passou de 22 variáveis preditoras originais para um vetor final de 95 *features*, aplicando a técnica de *One-Hot Encoding*, de modo à evitar a multicolinearidade induzida, a qual ocorre quando uma variável pode ser escrita como uma combinação linear exata de outras.

Para algoritmos sensíveis ao cálculo de distâncias em espaços multidimensionais (como KNN, SVM e Redes Neurais), os dados sofreram padronização (*Z-score normalization*), onde cada atributo foi reescalonado para possuir média zero e desvio padrão igual a um. Importante ressaltar que o aprendizado dessa escala foi rigorosamente isolado: o cálculo da média e do desvio padrão foi extraído exclusivamente dos dados de treinamento. Essa regra foi então aplicada aos dados de teste sem recalcular seus parâmetros internos, garantindo que o modelo não tivesse acesso prévio a informações do conjunto de avaliação (*data leakage*). Para que assim fosse possível realizar o levantamento e análise dos resultados obtidos do *dataset*.

5. Resultados e Discussões

A avaliação dos modelos, sumarizada na Tabela 1 e na Tabela 2, demonstrou que a alta acurácia global não é garantia de segurança biológica. Em um cenário de validação cruzada contendo 1.625 instâncias de teste (sendo 783 da classe venenosa), a maioria dos algoritmos obteve taxas de acerto acima de 98%, mas falhou no rigor da Revocação.

O *Naive Bayes* implementado com a distribuição de Bernoulli obteve o pior desempenho crítico do experimento. Apesar de uma acurácia razoável de 92,86%, o modelo registrou 108 Falsos Negativos, despencando sua Revocação para 86,21%. Esse resultado prova que a suposição de independência estrita entre características binárias falhou em capturar os padrões morfológicos complexos que definem as toxinas nas famílias *Agaricus* e *Lepiota*, tornando o modelo inaceitável para aplicações do mundo real.

Modelos baseados em distâncias espaciais e hiperplanos apresentaram vulnerabilidades pontuais. O KNN (com K=5), as Redes Neurais (MLP) e o Random Forest

alcançaram 99,88% de acurácia, mas deixaram passar 2 espécimes venenosos (Revocação de 99,74%). O aumento da regularização no KNN (K=29) apenas degradou a performance, aumentando os Falsos Negativos para 5. O SVM com *kernel* Sigmoid, conforme antecipado na análise da Curva Precision-Recall 3.1, sofreu para separar as classes de forma não linear, resultando em 16 classificações de risco biológico.

O algoritmo ótimo absoluto para esta base de dados foi a Árvore de Decisão paramerizada com profundidade máxima (*max_depth*) igual a oito. Ela foi a única arquitetura matemática a registrar **zero Falsos Negativos**, atingindo 100% de Revocação e 100% de Precisão na identificação da classe tóxica. O particionamento baseado na Entropia foi capaz de criar nós de decisão exatos, isolando perfeitamente os traços letais sem sacrificar os cogumelos comestíveis (zero Falsos Positivos). A limitação da árvore para uma profundidade de 6 reintroduziu o erro (2 Falsos Negativos), comprovando que a complexidade exata para mapear as exceções morfológicas deste *dataset* reside na oitava ramificação estrutural.

5.1. Desempenho Individual dos Modelos

A avaliação inicial permitiu mapear os resultados e configurações ótimas de cada um dos algorítimos. Para consolidar o processo, apresenta-se a 1, consolidando a acurácia e as matrizes de confusão para os hiperparâmetros ótimos.

Tabela 1. Matrizes de Confusão e Acurácia Bruta dos Modelos Testados

Algoritmo	Configuração Principal	Acurácia	Matriz de Confusão
KNN	K=5	99,88%	$\begin{bmatrix} 842 & 0 \\ 2 & 781 \end{bmatrix}$
KNN	K=29 (e K=30)	99,69%	$\begin{bmatrix} 842 & 0 \\ 5 & 778 \end{bmatrix}$
Naive Bayes	Gaussian	94,95%	$\begin{bmatrix} 762 & 80 \\ 2 & 781 \end{bmatrix}$
Naive Bayes	Bernoulli	92,86%	$\begin{bmatrix} 834 & 8 \\ 108 & 675 \end{bmatrix}$
Árvore de Decisão	max_depth=8	**100,00%**	$\begin{bmatrix} 842 & 0 \\ 0 & 783 \end{bmatrix}$
Árvore de Decisão	max_depth=6	99,88%	$\begin{bmatrix} 842 & 0 \\ 2 & 781 \end{bmatrix}$
Random Forest	n_estimators=9, max_depth=15	99,88%	$\begin{bmatrix} 842 & 0 \\ 2 & 781 \end{bmatrix}$
SVM	kernel='sigmoid'	98,58%	$\begin{bmatrix} 835 & 7 \\ 16 & 767 \end{bmatrix}$
Redes Neurais (MLP)	hidden_layer_sizes=[10]	99,88%	$\begin{bmatrix} 842 & 0 \\ 2 & 781 \end{bmatrix}$

5.2. Análise Comparativa pela Métrica de Revocação (Recall)

Analisando mais a fundo o principal critério para definição de um modelo ótimo para o problema descrito, foi levantada as métricas de Precisão e Revocação, mas agora sumarizados na tabela 2.

Tabela 2. Métricas de Desempenho Focadas na Classe Venenosa (Classe 1)

Algoritmo	Precisão	Revocação (Recall)	Falsos Negativos
KNN (K=5)	100,00%	99,74%	2
KNN (K=29)	100,00%	99,36%	5
Naive Bayes (Gaussian)	90,71%	99,74%	2
Naive Bayes (Bernoulli)	98,83%	86,21%	108
Árvore de Decisão (depth=8)	**100,00%**	**100,00%**	**0**
Árvore de Decisão (depth=6)	100,00%	99,74%	2
Random Forest	100,00%	99,74%	2
SVM (Sigmoid)	99,10%	97,96%	16
Redes Neurais (MLP)	100,00%	99,74%	2

De acordo com os dados obtidos, é importante frizar novamente que mesmo com acurácia global elevada, acontecem vazamentos inaceitáveis na Revocação dos métodos, que poderiam levar indivíduos à morte. No algoritimo Naive Bayes e no SVM, margens inaceitáveis foram configuradas. A única que de fato obteve Revocação absoluta foi a Árvore de Decisão (depth=8). E afim de detalhar ainda mais os resultados

A validação provou a estabilidade dos cortes da Árvore de Decisão sob variação amostral (Figura 3). Estruturas como *Random Forest* e Redes Neurais também registraram desempenho inabalável $(1,0000 \pm 0,0000)$. Diante do empate técnico no limite preditivo, a **Árvore de Decisão** isola-se como a arquitetura ideal com base no Princípio da Parcimônia (Navalha de Ockham): ela entrega segurança biológica absoluta exigindo uma fração do custo computacional das redes profundas, ao mesmo tempo em que oferece uma arquitetura transparente cujas regras de extração de características não operam no obscurantismo das caixas-pretas.

Para garantir que a performance perfeita da Árvore de Decisão não fosse um artefato de sobreajuste (*overfitting*) causado pela separação estática do teste, submeteu-se a arquitetura ao rigor da Validação Cruzada Estratificada com 5 cortes (*Stratified 5-Fold*). A consolidação computacional gerou médias e desvios padrões que atestam a robustez estrutural das predições, conforme a Figura 3.

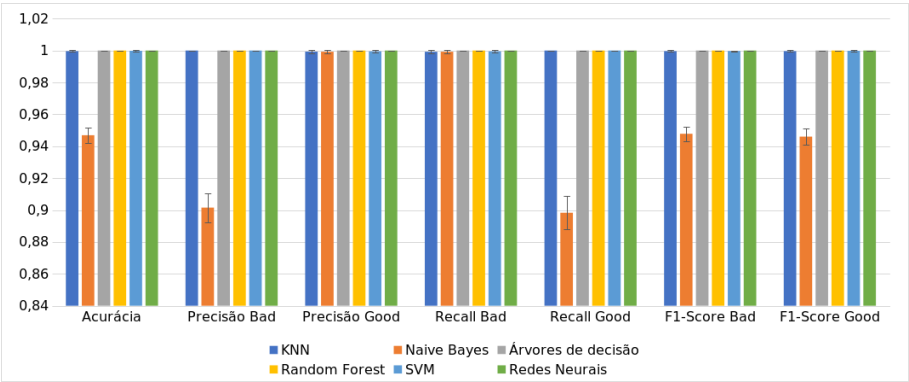

Figura 3. Validação cruzada dos algoritimos

5.3. Análise da importância das *features* do modelo superior

E a fim de entender a dominância absoluta do modelo no *dataset*, a Tabela 3 quantifica o peso matemático de cada variável biológica no processo decisório do algoritmo. Com uma dominância de 62,38%, o atributo **Odor** confirma-se não apenas como a *feature* estatisticamente mais preditiva, mas como a principal linha de defesa lógica contra a toxicidade.

Tabela 3. Importância das Características (*Feature Importance*) extraída do modelo de Árvore de Decisão

Posição	Atributo (*Feature*)	Importância Relativa (%)
1º	Odor (`odor`)	62,38%
2º	Cor da impressão dos esporos (`spore-print-color`)	21,25%
3º	Tamanho da lamela (`gill-size`)	11,21%
4º	Espaçamento da lamela (`gill-spacing`)	3,02%
5º	Formato do estipe (`stalk-shape`)	2,14%

E onde ocorre ambiguidade olfativa, o modelo utiliza morfologia reprodutiva — especificamente a cor da impressão dos esporos (*spore-print-color*, com 21,25%) de importância - e para estrutura física das lamelas -(*gill-size* e *gill-spacing*, somando cerca de 14,2%)- provando que o agrupamento de atributos sensoriais primários carrega o maior vetor de informação sobre o risco de letalidade da espécie.

6. Conclusões

A aplicação de técnicas de Aprendizado de Máquina ao problema de classificação de cogumelos revelou-se altamente eficaz. Considerando a natureza crítica do problema — onde o consumo de um espécime incorreto pode ser fatal —, a análise dos resultados exige uma avaliação rigorosa que vai além da simples Acurácia.

A métrica mais adequada e prioritária para este caso de estudo é a Revocação (*Recall* ou Sensibilidade) para a classe positiva (Venenoso). Em problemas de classificação na área de saúde ou segurança, os erros não possuem o mesmo peso, onde um falso negativo (Revocação) pode levar à morte de um indivíduo.

Portanto, o modelo ideal para este contexto é aquele que maximiza a Revocação da classe venenosa, minimizando (ou zerando) os Falsos Negativos, o único algorítimo que se encaixa nessa ideia é a Árvore de decisão. Mesmo que isso custe uma leve queda na Precisão (*Precision*), resultando em alguns Falsos Positivos aceitáveis, a Revocação deve ser absoluta.

6.1. Considerações Finais

A análise dos algorítimos também demonstrou que algoritmos como Random Forest e Árvores de Decisão (com profundidade adequada) alcançam um desempenho excepcional na base de dados *Mushroom*, embora não tenham 100% de revocação. As matrizes de confusão e as curvas ROC demonstram taxas altíssimas de separabilidade das classes. Conclui-se, assim, que as características morfológicas catalogadas contêm um padrão informacional forte o suficiente para que o risco humano no consumo de cogumelos selvagens possa ser mitigado quase na sua totalidade pelo uso de Inteligência Artificial.

6.2. Superioridade Metodológica frente ao Estado da Arte

A superioridade empírica deste estudo em relação aos trabalhos correlatos descritos anteriormente na Sessão 2 reside na solidez da arquitetura metodológica, que se sustenta em três pilares fundamentais. A pesquisa atual rompe com o paradigma da Acurácia Global adotado por grande parte da literatura. Enquanto trabalhos anteriores celebram taxas de acerto na casa dos 95% a 98% — o que, em um domínio de risco biológico, mascara dezenas de Falsos Negativos letais —, este estudo modela o problema estritamente como uma contenção de risco, elevando a Revocação (*Recall*) a 100% como o único critério aceitável de sucesso preditivo tornando o modelo mais confiável.

Conclusivamente, a consolidação da Árvore de Decisão como algoritimo superior fundamenta-se no Princípio da Parcimônia (Navalha de Ockham). Embora modelos de aprendizado profundo (Redes Neurais) e métodos de *Ensemble* (Random Forest) também tenham atingido o limite matemático do problema ($1,0000 \pm 0,0000$), a Árvore de Decisão entrega a mesma segurança absoluta exigindo uma fração do custo computacional.

Referências

Breiman, L. (2001). Random forests. *Machine learning*, 45(1):5–32.

Bruce, P. and Bruce, A. (2017). *Practical Statistics for Data Scientists: 50 Essential Concepts*. O'Reilly Media.

Chitayae, N. and Sunyoto, A. (2020). Performance comparison of mushroom types classification using k-nearest neighbor method and decision tree method. In *2020 3rd international conference on information and communications technology (ICOIACT)*, pages 308–313. IEEE.

Cover, T. (1968). Nearest neighbor pattern classification. *IEEE Trans. Information Theory*, 4(5):515–516.

Geisser, S. (1975). The predictive sample reuse method with applications. *Journal of the American statistical Association*, 70(350):320–328.

Gobinath, A., Rajeswari, P., Anandan, M., et al. (2024). Automated mushroom species identification and prediction using image processing and machine learning. In *2024 International BIT Conference (BITCON)*, pages 1–5. IEEE.

Hamonangan, R. (2021). Accuracy of classification poisonous or edible of mushroom using naïve bayes and k-nearest neighbors. *Journal of Soft Computing Exploration*.

Hand, D. J. and Yu, K. (2001). Idiot's bayes—not so stupid after all? *International statistical review*, 69(3):385–398.

James, G., Witten, D., Hastie, T., Tibshirani, R., et al. (2013). *An introduction to statistical learning: with applications in R*, volume 103. Springer.

Khasanah, H. M., Aminuddin, A., Abdulloh, F. F., Rahardi, M., Hairani, H., and Asaddulloh, B. P. (2024). Optimizing mushroom classification through machine learning and hyperparameter tuning. *Engineering and Applied Science Research*, 51(5):651–660.

Lavanya, B. and Preethi, G. (2017). Performance analysis of decision tree algorithms on mushroom dataset. *International Journal for Research in Applied Science and Engineering Technology*, 5(11):183–191.

Mathur, A., Mukherjee, A., and Dey, S. (2026). Mushroom edibility classification using analytical attention layers: A methodological study.

Neogi, A. (2025). *Critical Analysis of Machine Learning and Deep Learning Models for Mushroom Classification*. PhD thesis, Dublin, National College of Ireland.

Ortega, J., Lagman, A. C., Natividad, L. R. Q., Bantug, E. T., Resureccion, M. R., and Manalo, L. (2020). Analysis of performance of classification algorithms in mushroom poisonous detection using confusion matrix analysis. *International Journal*, 9(1.3).

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., et al. (2011). Scikit-learn: Machine learning in python. *the Journal of machine Learning research*, 12:2825–2830.

Quinlan, J. R. (1986). Induction of decision trees. *Machine learning*, 1(1):81–106.

Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1986). Learning representations by back-propagating errors. *nature*, 323(6088):533–536.

Sahu, R., Pandey, S., Verma, R., and Pandey, P. (2024). Ensemble learning based classification of edible and poisonous agaricus mushrooms. In *2024 Fourth International Conference on Advances in Electrical, Computing, Communication and Sustainable Technologies (ICAECT)*, pages 1–7. IEEE.

Schlimmer, J. (1987). Mushroom classification: Edible or poisonous? Kaggle. Dataset extraído do UCI Machine Learning Repository.

Van Rijsbergen, C. J. (1986). A non-classical logic for information retrieval. *The computer journal*, 29(6):481–485.

Vapnik, V. (1995). Support-vector networks. *Machine learning*, 20:273–297.

Wibowo, A., Rahayu, Y., Riyanto, A., and Hidayatulloh, T. (2018). Classification algorithm for edible mushroom identification. In *2018 International Conference on Information and Communications Technology (ICOIACT)*, pages 250–253. IEEE.