CEFET/RJ

TÉCNICAS DE APRENDIZADO DE MÁQUINA

Bacharelado em Sistemas da Informação

Prof. Marco André Abud Kappel

Aula 5 – Naive Bayes

Estatística

- **Noções básicas de estatística**
  - **Probabilidade** é a medida da chance de um **evento** ocorrer, expressa em uma escala de 0 a 1.
  - Para calcular uma probabilidade, basta dividir o **número de ocorrências** pelo número de resultados possíveis dentro do **espaço amostral**.
  - Seja A um evento. A probabilidade de que o evento A ocorra é dado por:

$$P(A) = \frac{\text{número de ocorrências de } A}{\text{tamanho do espaço amostral}}$$

Estatística

- **Noções básicas de estatística**
  - Exemplo: Qual é a probabilidade de jogarmos um dado e sair o valor 2?

Estatística

- **Noções básicas de estatística**
  - Exemplo: Qual é a probabilidade de jogarmos um dado e sair o valor 2?

$$P(2) = \frac{\textit{número de ocorrências de } 2}{\textit{tamanho do espaço amostral}}$$

Estatística

- **Noções básicas de estatística**
  - Exemplo: Qual é a probabilidade de jogarmos um dado e sair o valor 2?

$$P(2) = \frac{\textit{número de ocorrências de 2}}{\textit{tamanho do espaço amostral}}$$

$$P(2) = \frac{1}{6} = 0{,}167$$

Estatística

- **Noções básicas de estatística**
  - Quando dois eventos aleatórios são **independentes**, a probabilidade de **ambos ocorrerem** simultaneamente pode ser obtida pela **multiplicação** das probabilidades individuais.
  - Seja A um evento e B outro evento, a probabilidade de A e B ocorrerem simultaneamente é dada por:

$$P(A\ e\ B) = P(A)\ \cdot P(B)$$

Estatística

- **Noções básicas de estatística**
  - Exemplo: Qual é a probabilidade de jogarmos dois dados e os valores 3 e 4 saírem simultaneamente?

Estatística

- **Noções básicas de estatística**
  - Exemplo: Qual é a probabilidade de jogarmos dois dados e os valores 3 e 4 saírem simultaneamente?

$$P(3) = \frac{\textit{número de ocorrências de } 3}{\textit{tamanho do espaço amostral}}$$

$$P(4) = \frac{\textit{número de ocorrências de } 4}{\textit{tamanho do espaço amostral}}$$

Estatística

- **Noções básicas de estatística**
  - Exemplo: Qual é a probabilidade de jogarmos dois dados e os valores 3 e 4 saírem simultaneamente?

$$P(3) = \frac{1}{6} \qquad P(4) = \frac{1}{6}$$

$$P(A\ e\ B) = P(A) \cdot P(B)$$

Estatística

- **Noções básicas de estatística**
  - Exemplo: Qual é a probabilidade de jogarmos dois dados e os valores 3 e 4 saírem simultaneamente?

$$P(3) = \frac{1}{6} \qquad P(4) = \frac{1}{6}$$

$$P(A\ e\ B) = P(A)\ \cdot P(B)$$

$$P(A\ e\ B) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36} = 0{,}0278$$

Estatística

- **Noções básicas de estatística**
  - **Média** é uma medida de **tendência central** que busca o valor médio de uma série histórica.

$$\mu = \frac{\sum X}{N}$$

Soma de todas os valores ocorridos

Tamanho da população

  - **Desvio padrão** mede a **dispersão** ou **concentração** dos dados em torno da média.

$$\sigma = \sqrt{\frac{\sum (X - \mu)^2}{N}}$$

Estatística

- **Noções básicas de estatística**
  - **Exemplo:** Suponha que os alunos de uma turma obtiveram as seguintes notas:

Aluno	Nota
Alice	8,0
Bruno	7,0
Carla	6,0
Daniel	9,0
Emily	5,0

Estatística

- **Noções básicas de estatística**
  - **Exemplo:** Suponha que os alunos de uma turma obtiveram as seguintes notas:

Aluno	Nota
Alice	8,0
Bruno	7,0
Carla	6,0
Daniel	9,0
Emily	5,0

- Para calcular a **média**, você soma todas as notas e divide pelo número de alunos:

$$Média = (8 + 7 + 6 + 9 + 5) / 5 = \mathbf{7}$$

Estatística

- **Noções básicas de estatística**
  - **Exemplo:** Suponha que os alunos de uma turma obtiveram as seguintes notas:

Aluno	Nota
Alice	8,0
Bruno	7,0
Carla	6,0
Daniel	9,0
Emily	5,0

- Para calcular o **desvio padrão**, aplicamos a fórmula:

$$\sigma = \sqrt{\frac{(8-7)^2 + (7-7)^2 + (6-7)^2 + (9-7)^2 + (5-7)^2}{5}}$$

$$\sigma = \sqrt{\frac{1+0+1+4+4}{5}} = \sqrt{\frac{10}{5}} = \sqrt{2} \cong \mathbf{1,41}$$

Estatística

- **Noções básicas de estatística**
  - A média representa o valor típico das notas, enquanto o desvio padrão mostra o quanto as notas estão dispersas em torno da média. Quanto maior o desvio padrão, mais dispersas estão as notas.

- Neste exemplo, as notas têm uma média de 7, com um desvio padrão de aproximadamente 1,41, indicando que as notas estão relativamente próximas da média.

Aluno	Nota
Alice	8,0
Bruno	7,0
Carla	6,0
Daniel	9,0
Emily	5,0

Estatística

- **Noções básicas de estatística**
  - A **distribuição de probabilidade** é uma função que atribui uma probabilidade a cada resultado possível em um espaço amostral.
  - Graficamente, a distribuição mostra qual é a **probabilidade** de que cada evento ocorra dentro do espaço amostral.
  - Algumas das principais **distribuições de probabilidade**:

Uniforme

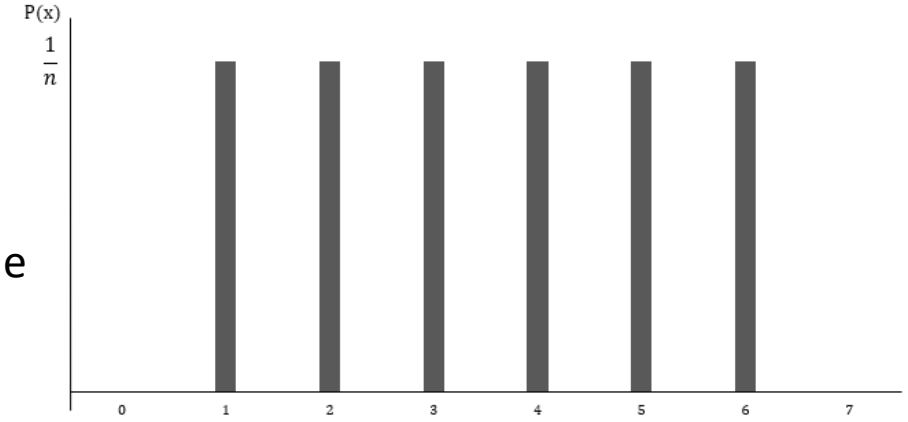

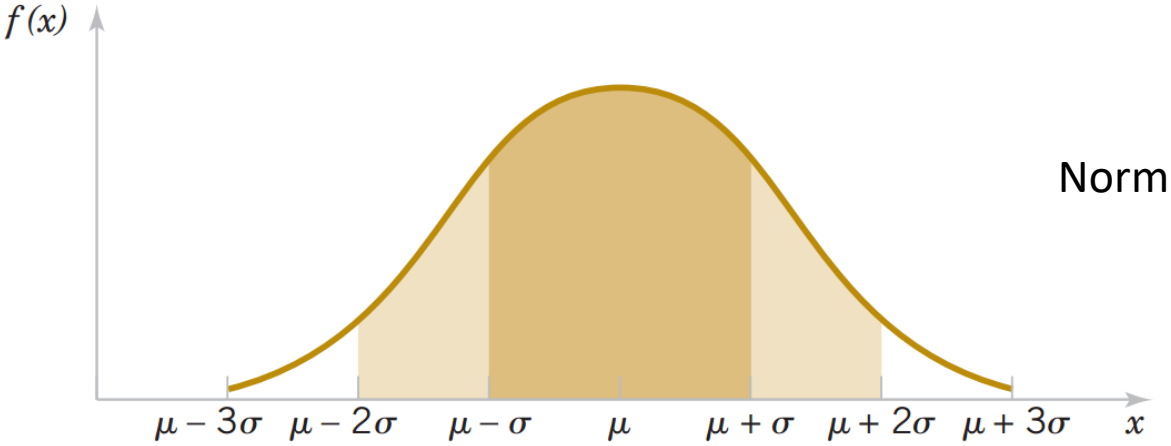

Normal

Estatística

- **Noções básicas de estatística**
  - A **Distribuição Normal** é uma das mais utilizadas na modelagem estatística.

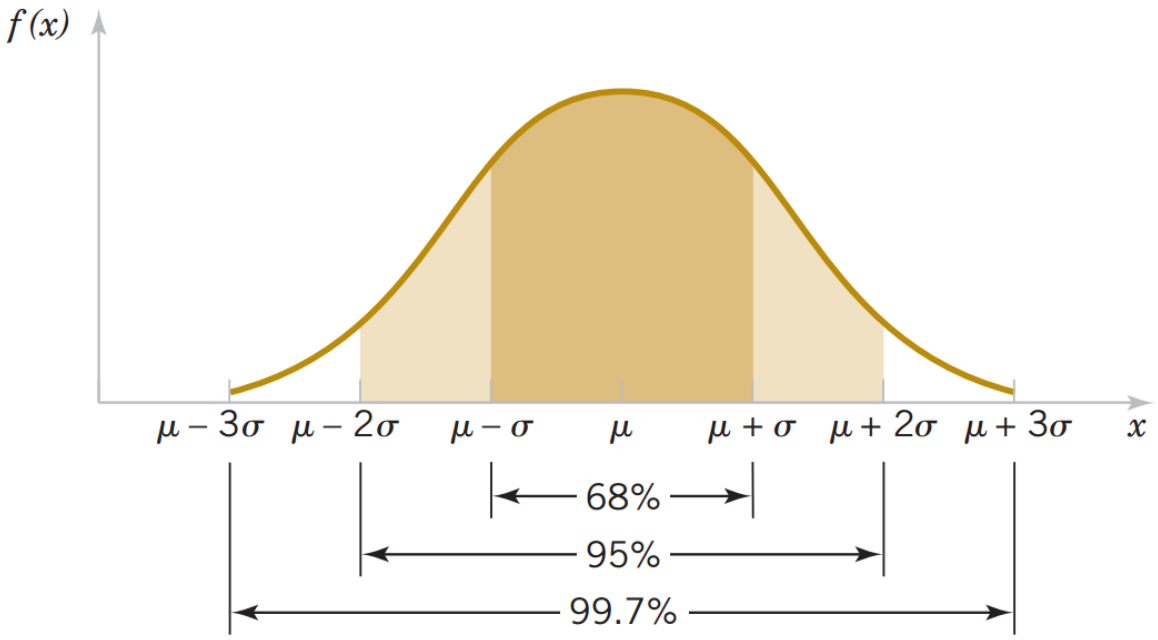

Estatística

- **Noções básicas de estatística**
  - Você consegue identificar qual é a distribuição de probabilidade correta para os exemplos que vimos?

Uniforme

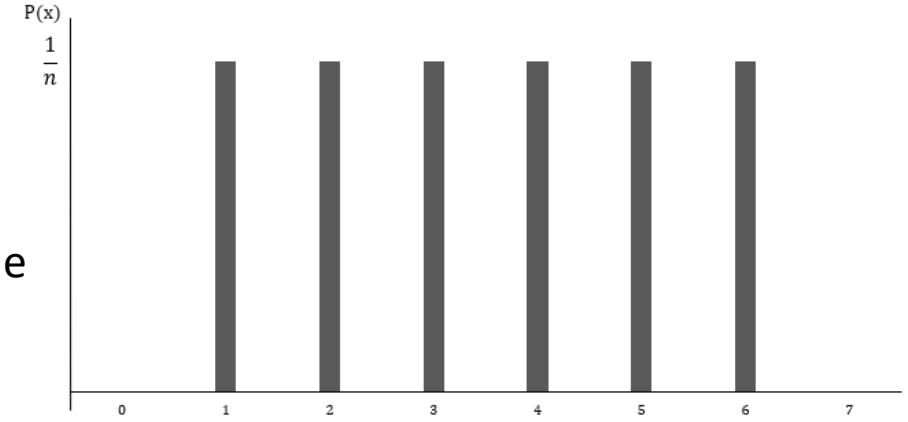

Normal

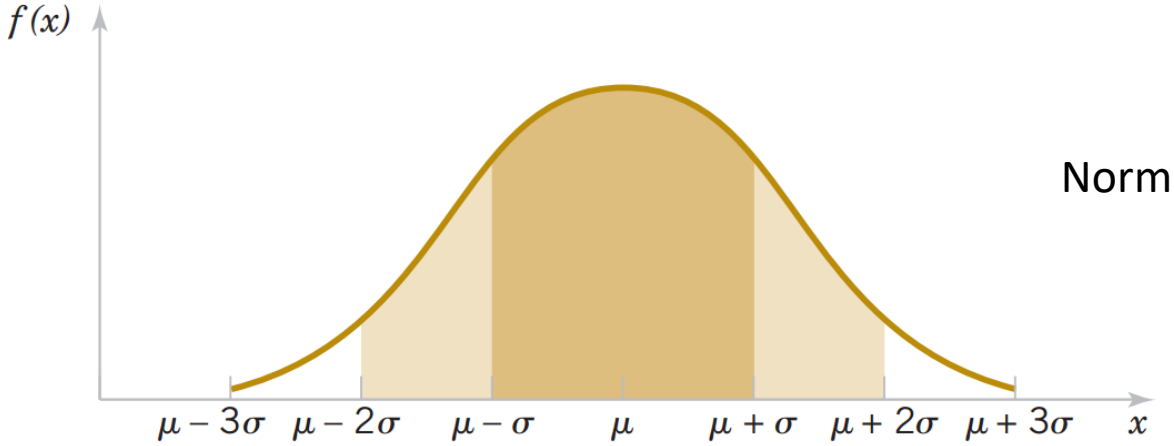

Estatística

- **Noções básicas de estatística**
  - Você consegue identificar qual é a distribuição de probabilidade correta para os exemplos que vimos?

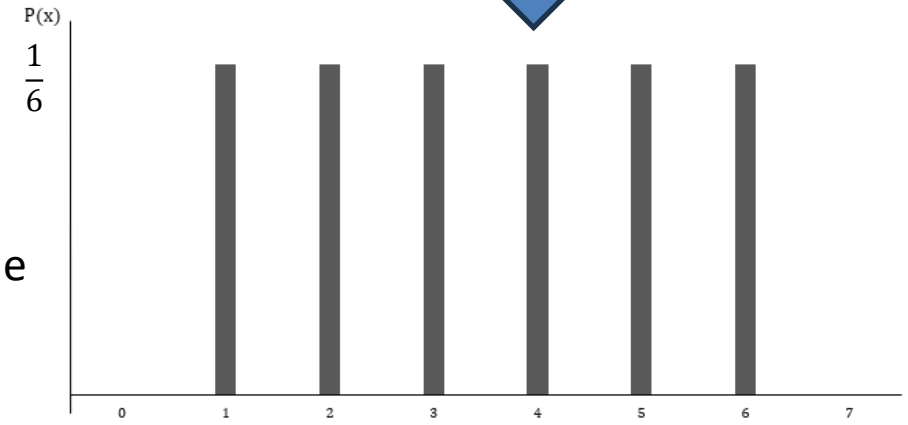

Uniforme

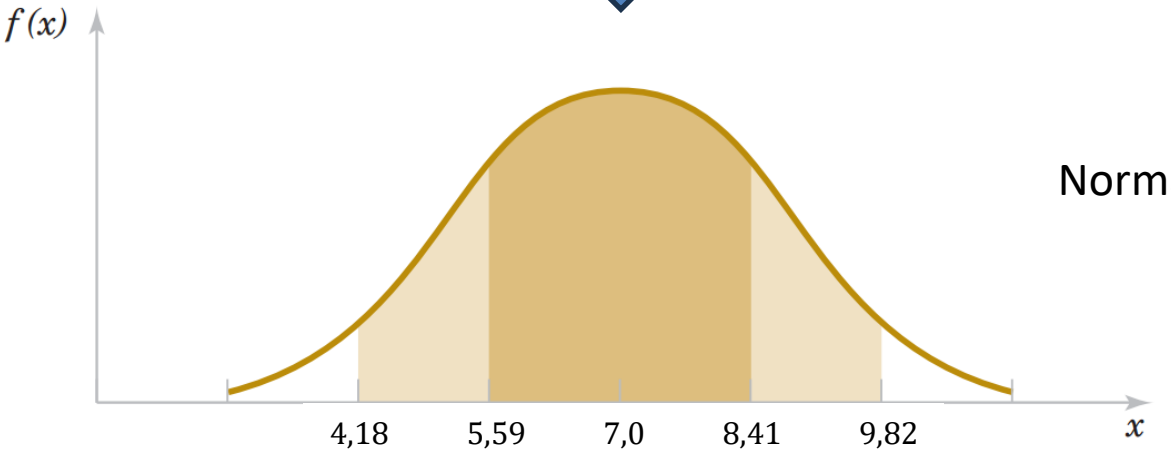

Normal

Estatística

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\left[\sum_{i=1}^{n}(x_i - \bar{x})^2\right]\left[\sum_{i=1}^{n}(y_i - \bar{y})^2\right]}}$$

- **Noções básicas de estatística**
  - A **Correlação de Pearson** é uma medida estatística que nos ajuda a entender como duas variáveis estão **relacionadas** entre si. Essa medida é representada por um número que varia entre -1 e 1.
  - Se duas variáveis têm uma **correlação positiva**, isso significa que elas tendem a **crescer juntas**.

➢ Por exemplo, se medirmos a **altura** de uma pessoa e o tamanho de seus **pés**, veremos que essas duas variáveis têm uma **correlação positiva**, pois as pessoas mais altas tendem a ter pés maiores.

Estatística

- **Noções básicas de estatística**
  - Já se duas variáveis têm uma **correlação negativa**, isso significa que elas tendem a crescer em **direções opostas**.

➢ Por exemplo, se medirmos a quantidade de **horas de sono** de uma pessoa e seu **nível de estresse**, veremos que essas duas variáveis têm uma **correlação negativa**, pois quando uma delas aumenta, a outra tende a diminuir.

Estatística

- **Noções básicas de estatística**
  - Se duas variáveis **não têm correlação**, isso significa que elas não estão relacionadas entre si.
  - Nestes casos, a correlação será próxima de zero e dizemos que as variáveis são **linearmente independentes**.

➢ Por exemplo, se medirmos a **altura** de uma pessoa e sua **tonalidade de cabelo**, não veremos uma correlação significativa entre essas duas variáveis.

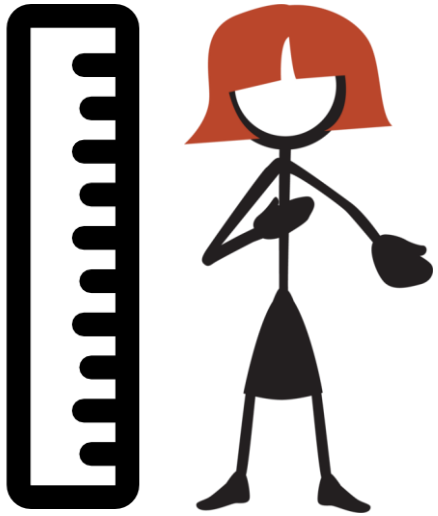

Estatística

- **Correlação X causalidade**
  - A diferença entre **correlação** e **causalidade** é fundamental para entender como os eventos e variáveis **se relacionam** entre si.
  - A correlação descreve a **relação** entre duas variáveis, mostrando como elas **mudam juntas**.
  - No entanto, a correlação **não implica** necessariamente uma relação de **causa e efeito** entre as variáveis.

Importante!

Estatística

- **Correlação X causalidade**
  - Estabelecer causalidade requer **evidências mais robustas** do que apenas **observar correlações**.
  - Por exemplo: considere a relação entre o **consumo de sorvete** e o **número de afogamentos** em uma cidade.

➢ Obviamente, existe a **correlação**. Mas existe causalidade?

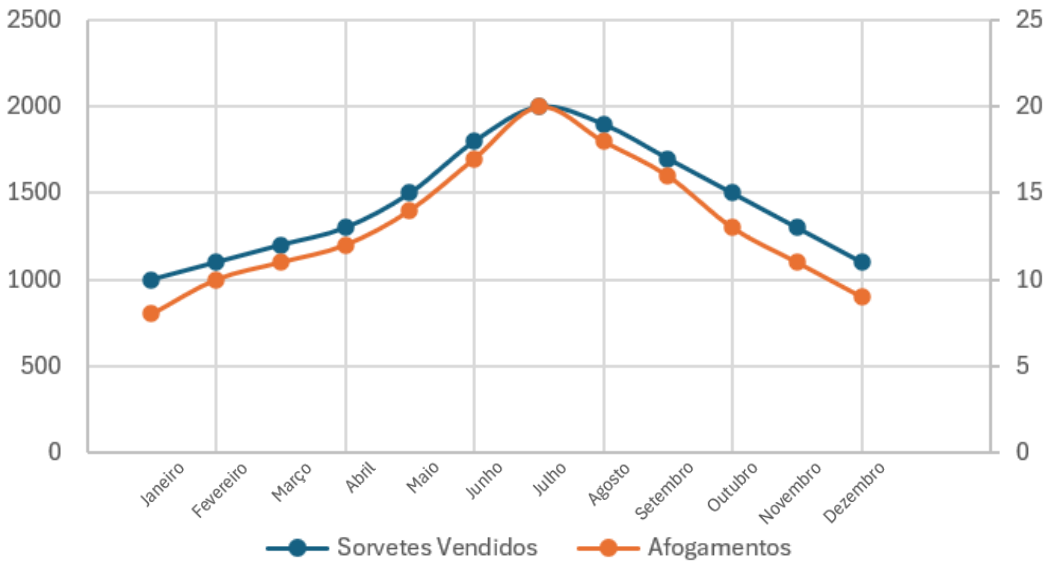

Estatística

- **Correlação X causalidade**
  - Não! Um especialista analisando o caso com mais profundidade poderia mostrar que essa associação deixa de existir quando uma **terceira variável** é levada em consideração: a **temperatura**.

➢ Ambas as variáveis dependem da variável **temperatura**, mas não possuem causalidade entre si.

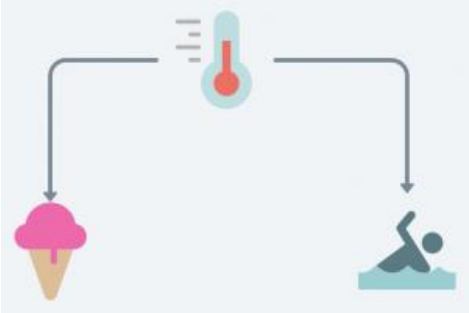

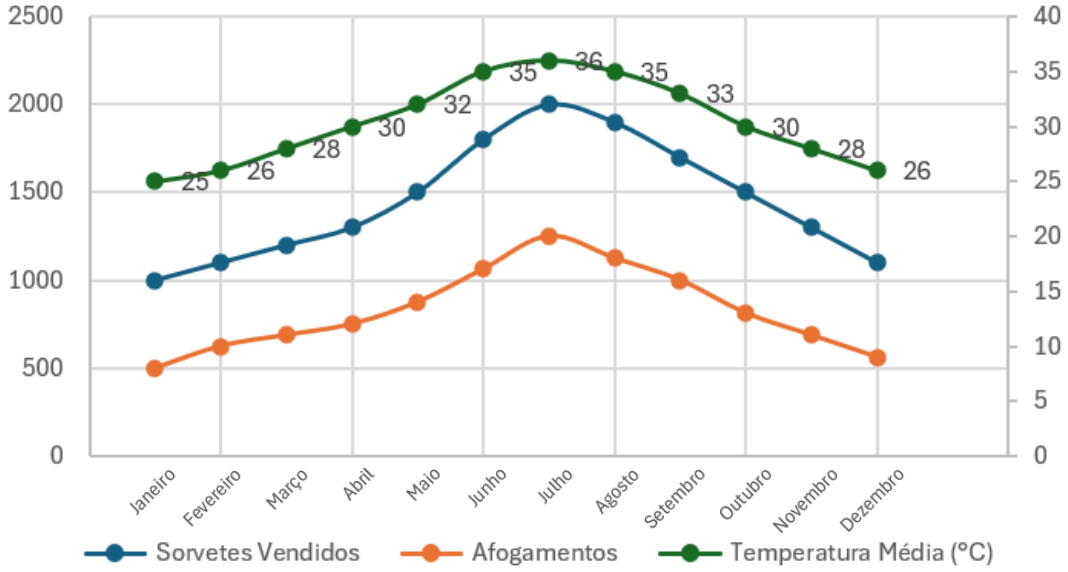

Estatística

- **Correlação X causalidade**
  - **Entender** a diferença entre correlação e causalidade é crucial para **interpretar** dados corretamente e **tomar decisões** informadas em várias áreas, incluindo ciência, economia, saúde e política.
  - Em muitos casos, dois eventos irão **parecer associados** por desconhecermos ao menos uma **terceira variável** que é a causadora de ambos.

Estatística

- **Correlação X causalidade**
  - Uma **técnica básica** para identificar se estamos lidando com uma relação de causalidade é realizar uma **Análise de Sensibilidade**.
  - Esta técnica que envolve manipular **uma variável de cada vez** e observar como isso **afeta** outras variáveis, ajudando a identificar possíveis **relações de causalidade** e compreender melhor o contexto dos dados.

➢ Isso demanda **experimentos controlados** com diferentes **grupos de controle**.

➢ A produtividade é afetada quando ouvimos música?

Estatística

- **Spurious Correlations**

– É um site que destaca **correlações estatísticas** entre variáveis que **não têm relação causal** real.

www.spuriouscorrelations.com

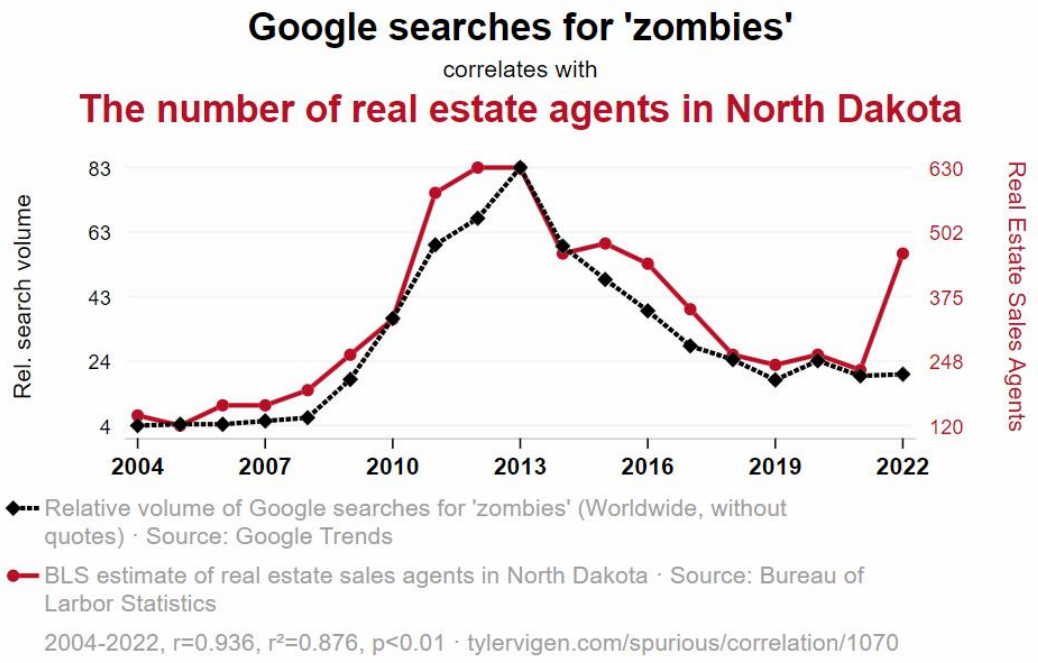

View details about correlation #1,070

Zombie Zeal and Real Estate: A Zany Zombieland Zest for Zombie Searches and Zesty Zillow Zones

Show GenAI's made-up explanation

As more people prepared for a potential zombie apocalypse, the demand for underground bunkers in North Dakota skyrocketed, leading to a boom in the real estate market and a sudden need for more agents to facilitate these unconventional property transactions. "Even the undead can't resist that North Dakota charm!"

Naive Bayes

Naive Bayes

- **Introdução**
  - A técnica **Naive Bayes** é uma abordagem probabilística ao problema de classificação.
  - Baseada diretamente no **Teorema de Bayes**.
  - Utilizada principalmente no processamento de **textos**, considerando as **palavras mais frequentes**.
  - Exemplos de aplicação:
    - Filtros de spam
    - Mineração de emoções
    - Separação de documentos

Naive Bayes

- **Introdução**
  - A técnica tem como base a suposição de **independência** entre os atributos preditores.
  - Em termos simples, um classificador Naive Bayes assume que a presença de uma característica particular em uma classe **não está relacionada** com a presença de qualquer outra.
    - ➢ Por exemplo, um fruto pode ser considerado como uma maçã se é **vermelho**, **redondo**, e tiver cerca de 3 polegadas de **diâmetro**.

– A técnica assume que todas estas propriedades contribuem de forma independente para a **probabilidade** deste fruto ser uma maçã.

– Por isso que é conhecida como ‘Naive’ (ingênuo).

Naive Bayes

- **Introdução**
  - O Teorema de Bayes fornece uma forma de calcular a **probabilidade posterior** a partir das **probabilidades anteriores**.

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

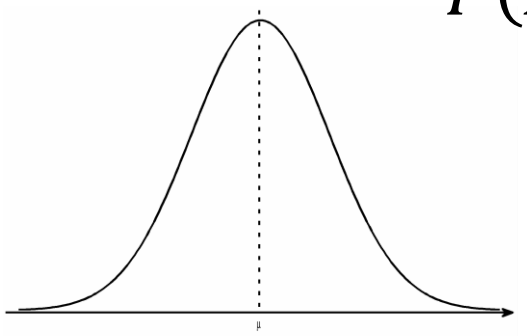

Naive Bayes

- **Introdução**
  - O Teorema de Bayes fornece uma forma de calcular a **probabilidade posterior** a partir das **probabilidades anteriores**.

Probabilidade de ocorrer A dado que B já ocorreu.

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

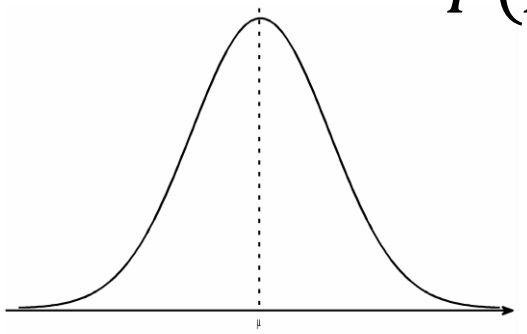

Naive Bayes

- **Introdução**
  - O Teorema de Bayes fornece uma forma de calcular a **probabilidade posterior** a partir das **probabilidades anteriores**.

Probabilidade de ocorrer A dado que B já ocorreu.

Probabilidade de ocorrer B dado que A já ocorreu.

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

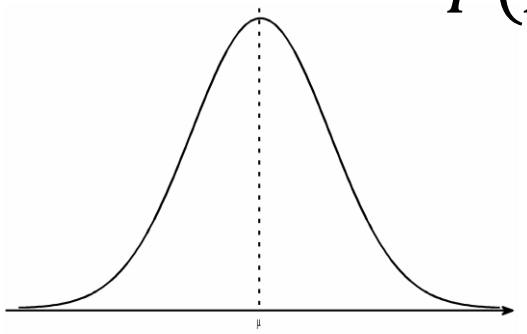

Naive Bayes

- **Introdução**
  - O Teorema de Bayes fornece uma forma de calcular a **probabilidade posterior** a partir das **probabilidades anteriores**.

Probabilidade de ocorrer A dado que B já ocorreu.

Probabilidade de ocorrer B dado que A já ocorreu.

Probabilidade de ocorrer A.

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Probabilidade de ocorrer B.

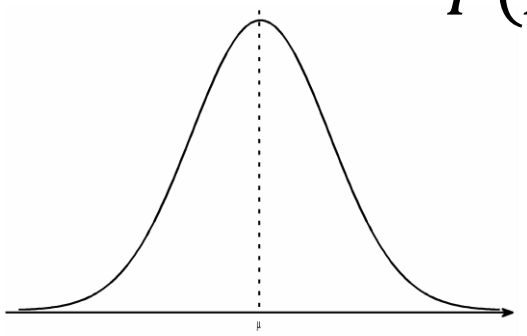

Naive Bayes

- **Introdução**
  - Quando aplicada em problemas de **classificação**, podemos **interpretar** a fórmula da seguinte maneira:

Probabilidade do registro ser da classe A, dado que possui as características B.

Probabilidade do registro possuir as características B, dado que é da classe A.

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Probabilidade de um registro ser da classe A.

Probabilidade de um registro possuir as características B.

Naive Bayes

- **Funcionamento**
  - Para mostrar como funciona o método Naive Bayes, vamos ver uma aplicação em uma base de dados simples.

História do crédito	Dívida	Garantias	Renda anual	Risco
Ruim	Alta	Nenhuma	< 15.000	Alto
Desconhecida	Alta	Nenhuma	>= 15.000 a <= 35.000	Alto
Desconhecida	Baixa	Nenhuma	>= 15.000 a <= 35.000	Moderado
Desconhecida	Baixa	Nenhuma	> 35.000	Alto
Desconhecida	Baixa	Nenhuma	> 35.000	Baixo
Desconhecida	Baixa	Adequada	> 35.000	Baixo
Ruim	Baixa	Nenhuma	< 15.000	Alto
Ruim	Baixa	Adequada	> 35.000	Moderado
Boa	Baixa	Nenhuma	> 35.000	Baixo
Boa	Alta	Adequada	> 35.000	Baixo
Boa	Alta	Nenhuma	< 15.000	Alto
Boa	Alta	Nenhuma	>= 15.000 a <= 35.000	Moderado
Boa	Alta	Nenhuma	> 35.0000	Baixo
Ruim	Alta	Nenhuma	>= 15.000 a <= 35.000	Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa	Desconhecida	Ruim							
Alto										
Moderado										
Baixo										

Risco
Alto
Alto
Moderado
Alto
Baixo
Baixo
Alto
Moderado
Baixo
Baixo
Alto
Moderado
Baixo
Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa	Desconhecida	Ruim							
Alto										
Moderado										
Baixo										

Risco
Alto
Alto
Moderado
Alto
Baixo
Baixo
Alto
Moderado
Baixo
Baixo
Alto
Moderado
Baixo
Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

		História do crédito			Dívida		Garantias		Renda anual		
	Risco de crédito	Boa	Desconhecida	Ruim							
$P(A)$	Alto										
	Moderado										
	Baixo										

Quantos registros temos com risco de crédito alto, dentre os 14?

Risco
Alto
Alto
Moderado
Alto
Baixo
Baixo
Alto
Moderado
Baixo
Baixo
Alto
Moderado
Baixo
Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa	Desconhecida	Ruim							
Alto 6/14										
Moderado										
Baixo										

$P(Alto)$

Quantos registros temos com risco de crédito alto, dentre os 14?

Risco
Alto
Alto
Moderado
Alto
Baixo
Baixo
Alto
Moderado
Baixo
Baixo
Alto
Moderado
Baixo
Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa	Desconhecida	Ruim							
Alto 6/14										
Moderado										
Baixo										

$P(Moderado)$

Quantos registros temos com risco de crédito moderado, dentre os 14?

Risco
Alto
Alto
Moderado
Alto
Baixo
Baixo
Alto
Moderado
Baixo
Baixo
Alto
Moderado
Baixo
Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa	Desconhecida	Ruim							
Alto 6/14										
Moderado 3/14										
Baixo										

$P(Moderado)$

Quantos registros temos com risco de crédito moderado, dentre os 14?

Risco
Alto
Alto
Moderado
Alto
Baixo
Baixo
Alto
Moderado
Baixo
Baixo
Alto
Moderado
Baixo
Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa	Desconhecida	Ruim							
Alto 6/14										
Moderado 3/14										
Baixo										

$P(Baixo)$

Quantos registros temos com risco de crédito baixo, dentre os 14?

Risco
Alto
Alto
Moderado
Alto
Baixo
Baixo
Alto
Moderado
Baixo
Baixo
Alto
Moderado
Baixo
Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa	Desconhecida	Ruim							
Alto 6/14										
Moderado 3/14										
Baixo 5/14										

$P(Baixo)$

Quantos registros temos com risco de crédito baixo, dentre os 14?

Risco
Alto
Alto
Moderado
Alto
Baixo
Baixo
Alto
Moderado
Baixo
Baixo
Alto
Moderado
Baixo
Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

$P(B)$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa	Desconhecida	Ruim							
Alto 6/14										
Moderado 3/14										
Baixo 5/14										

Para cada característica, precisamos contabilizar quantas estão presentes.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

  - Vamos construir uma tabela de probabilidades:

$P(Boa)$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa $\frac{5}{14}$	Desconhecida	Ruim							
Alto 6/14										
Moderado 3/14										
Baixo 5/14										

Para cada característica, precisamos contabilizar quantas estão presentes.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades: $P(Desconhecida)$

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa $\frac{5}{14}$	Desconhecida	Ruim							
Alto 6/14										
Moderado 3/14										
Baixo 5/14										

Para cada característica, precisamos contabilizar quantas estão presentes.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades: $P(Desconhecida)$

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim							
Alto 6/14										
Moderado 3/14										
Baixo 5/14										

Para cada característica, precisamos contabilizar quantas estão presentes.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

$P(Ruim)$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim							
Alto 6/14										
Moderado 3/14										
Baixo 5/14										

Para cada característica, precisamos contabilizar quantas estão presentes.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

  - Vamos construir uma tabela de probabilidades:

$P(Ruim)$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14										
Moderado 3/14										
Baixo 5/14										

Para cada característica, precisamos contabilizar quantas estão presentes.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14										
Moderado 3/14										
Baixo 5/14										

Cada elemento desta tabela corresponde à probabilidade conjunta da classe e a característica respectiva.

Neste caso, por exemplo, temos que colocar a probabilidade da história de crédito ser boa, dado que o risco é alto.

$P(B|A)$

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14										
Moderado 3/14										
Baixo 5/14										

Cada elemento desta tabela corresponde à probabilidade conjunta da classe e a característica respectiva.

Neste caso, por exemplo, temos que colocar a probabilidade da história de crédito ser boa, dado que o risco é alto.

$$P(Boa|Alto)$$

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6									
Moderado 3/14										
Baixo 5/14										

Cada elemento desta tabela corresponde à probabilidade conjunta da classe e a característica respectiva.

Neste caso, por exemplo, temos que colocar a probabilidade da história de crédito ser boa, dado que o risco é alto.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

$$P(Boa|Alto)$$

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6									
Moderado 3/14										
Baixo 5/14										

O mesmo deve ser feito para os outros valores de classe.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

$$P(Boa|Moderado)$$

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6									
Moderado 3/14										
Baixo 5/14										

O mesmo deve ser feito para os outros valores de classe.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

$$P(Boa|Moderado)$$

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6									
Moderado 3/14	1/3									
Baixo 5/14										

O mesmo deve ser feito para os outros valores de classe.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

$$P(Boa|Moderado)$$

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6									
Moderado 3/14	1/3									
Baixo 5/14										

O mesmo deve ser feito para os outros valores de classe.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

$$P(Boa|Baixo)$$

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6									
Moderado 3/14	1/3									
Baixo 5/14										

O mesmo deve ser feito para os outros valores de classe.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

$$P(Boa|Baixo)$$

- **Funcionamento**
  - Vamos construir uma tabela de probabilidades:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6									
Moderado 3/14	1/3									
Baixo 5/14	3/5									

O mesmo deve ser feito para os outros valores de classe.

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

$$P(Boa|Baixo)$$

- **Funcionamento**
  - O procedimento deve ser repetido para todas as característica, até que a tabela esteja completa.

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6									
Moderado 3/14	1/3									
Baixo 5/14	3/5									

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**
  - O procedimento deve ser repetido para todas as característica, até que a tabela esteja completa.

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6	2/6	3/6							
Moderado 3/14	1/3	1/3	1/3							
Baixo 5/14	3/5	2/5	0							

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

- **Funcionamento**
  - O procedimento deve ser repetido para todas as característica, até que a tabela esteja completa.

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$							
Alto 6/14	1/6	2/6	3/6							
Moderado 3/14	1/3	1/3	1/3							
Baixo 5/14	3/5	2/5	0							

Dívida	Risco
Alta	Alto
Alta	Alto
Baixa	Moderado
Baixa	Alto
Baixa	Baixo
Baixa	Baixo
Baixa	Alto
Baixa	Moderado
Baixa	Baixo
Alta	Baixo
Alta	Alto
Alta	Moderado
Alta	Baixo
Alta	Alto

- **Funcionamento**
  - O procedimento deve ser repetido para todas as característica, até que a tabela esteja completa.

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$	Alta $\frac{7}{14}$	Baixa $\frac{7}{14}$					
Alto 6/14	1/6	2/6	3/6	4/6	2/6					
Moderado 3/14	1/3	1/3	1/3	1/3	2/3					
Baixo 5/14	3/5	2/5	0	2/5	3/5					

Dívida	Risco
Alta	Alto
Alta	Alto
Baixa	Moderado
Baixa	Alto
Baixa	Baixo
Baixa	Baixo
Baixa	Alto
Baixa	Moderado
Baixa	Baixo
Alta	Baixo
Alta	Alto
Alta	Moderado
Alta	Baixo
Alta	Alto

- **Funcionamento**
  - O procedimento deve ser repetido para todas as característica, até que a tabela esteja completa.

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$	Alta $\frac{7}{14}$	Baixa $\frac{7}{14}$					
Alto 6/14	1/6	2/6	3/6	4/6	2/6					
Moderado 3/14	1/3	1/3	1/3	1/3	2/3					
Baixo 5/14	3/5	2/5	0	2/5	3/5					

Garantias	Risco
Nenhuma	Alto
Nenhuma	Alto
Nenhuma	Moderado
Nenhuma	Alto
Nenhuma	Baixo
Adequada	Baixo
Nenhuma	Alto
Adequada	Moderado
Nenhuma	Baixo
Adequada	Baixo
Nenhuma	Alto
Nenhuma	Moderado
Nenhuma	Baixo
Nenhuma	Alto

- **Funcionamento**
  - O procedimento deve ser repetido para todas as característica, até que a tabela esteja completa.

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$	Alta $\frac{7}{14}$	Baixa $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	Adequada $\frac{3}{14}$			
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0			
Moderado 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3			
Baixo 5/14	3/5	2/5	0	2/5	3/5	3/5	2/5			

Garantias	Risco
Nenhuma	Alto
Nenhuma	Alto
Nenhuma	Moderado
Nenhuma	Alto
Nenhuma	Baixo
Adequada	Baixo
Nenhuma	Alto
Adequada	Moderado
Nenhuma	Baixo
Adequada	Baixo
Nenhuma	Alto
Nenhuma	Moderado
Nenhuma	Baixo
Nenhuma	Alto

- **Funcionamento**
  - O procedimento deve ser repetido para todas as característica, até que a tabela esteja completa.

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$	Alta $\frac{7}{14}$	Baixa $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	Adequada $\frac{3}{14}$			
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0			
Moderado 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3			
Baixo 5/14	3/5	2/5	0	2/5	3/5	3/5	2/5			

Renda anual	Risco
< 15.000	Alto
>= 15.000 a <= 35.000	Alto
>= 15.000 a <= 35.000	Moderado
> 35.000	Alto
> 35.000	Baixo
> 35.000	Baixo
< 15.000	Alto
> 35.000	Moderado
> 35.000	Baixo
> 35.000	Baixo
< 15.000	Alto
>= 15.000 a <= 35.000	Moderado
> 35.0000	Baixo
>= 15.000 a <= 35.000	Alto

- **Funcionamento**
  - O procedimento deve ser repetido para todas as característica, até que a tabela esteja completa.

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$	Alta $\frac{7}{14}$	Baixa $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	Adequada $\frac{3}{14}$	< 15 $\frac{3}{14}$	>= 15 <= 35 $4/14$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0	3/6	2/6	1/6
Moderado 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0	2/3	1/3
Baixo 5/14	3/5	2/5	0	2/5	3/5	3/5	2/5	0	0	5/5

Renda anual	Risco
< 15.000	Alto
>= 15.000 a <= 35.000	Alto
>= 15.000 a <= 35.000	Moderado
> 35.000	Alto
> 35.000	Baixo
> 35.000	Baixo
< 15.000	Alto
> 35.000	Moderado
> 35.000	Baixo
> 35.000	Baixo
< 15.000	Alto
>= 15.000 a <= 35.000	Moderado
> 35.0000	Baixo
>= 15.000 a <= 35.000	Alto

Naive Bayes

- **Funcionamento**
  - Com isso, a fase de **treinamento** está concluída.
  - Com a tabela de probabilidades montada, podemos **estimar** a probabilidade de um **novo registro** ser de cada classe.

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$	Alta $\frac{7}{14}$	Baixa $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	Adequada $\frac{3}{14}$	< 15 $\frac{3}{14}$	>= 15 <= 35 $4/14$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0	3/6	2/6	1/6
Moderado 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0	2/3	1/3
Baixo 5/14	3/5	2/5	0	2/5	3/5	3/5	2/5	0	0	5/5

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$	Alta $\frac{7}{14}$	Baixa $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	Adequada $\frac{3}{14}$	< 15 $\frac{3}{14}$	>= 15 <= 35 $4/14$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0	3/6	2/6	1/6
Moderado 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0	2/3	1/3
Baixo 5/14	3/5	2/5	0	2/5	3/5	3/5	2/5	0	0	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

Novo registro

Para este conjunto de características B, vou calcular $P(A|B)$ para cada uma das classes A e descobrir a maior probabilidade!

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito			Dívida		Garantias		Renda anual		
Risco de crédito	Boa $\frac{5}{14}$	Desconhecida $\frac{5}{14}$	Ruim $\frac{4}{14}$	Alta $\frac{7}{14}$	Baixa $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	Adequada $\frac{3}{14}$	< 15 $\frac{3}{14}$	>= 15 <= 35 $4/14$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0	3/6	2/6	1/6
Moderado 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0	2/3	1/3
Baixo 5/14	3/5	2/5	0	2/5	3/5	3/5	2/5	0	0	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

Seleciono apenas as características do novo registro.

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito	Dívida	Garantias	Renda anual
Risco de crédito	Boa $\frac{5}{14}$	Alta $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	4/6	6/6	1/6
Moderado 3/14	1/3	1/3	2/3	1/3
Baixo 5/14	3/5	2/5	3/5	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

Seleciono apenas as características do novo registro.

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito	Dívida	Garantias	Renda anual
Risco de crédito	Boa $\frac{5}{14}$	Alta $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	4/6	6/6	1/6
Moderado 3/14	1/3	1/3	2/3	1/3
Baixo 5/14	3/5	2/5	3/5	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

O próximo passo é aplicar a fórmula.

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito	Dívida	Garantias	Renda anual
Risco de crédito	Boa $\frac{5}{14}$	Alta $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	4/6	6/6	1/6
Moderado 3/14	1/3	1/3	2/3	1/3
Baixo 5/14	3/5	2/5	3/5	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

$$P(Alto|B) = \frac{\left(\frac{1}{6}\right) * \left(\frac{4}{6}\right) * \left(\frac{6}{6}\right) * \left(\frac{1}{6}\right) * \left(\frac{6}{14}\right)}{\left(\frac{5}{14}\right) * \left(\frac{7}{14}\right) * \left(\frac{11}{14}\right) * \left(\frac{7}{14}\right)} = 0{,}113$$

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito	Dívida	Garantias	Renda anual
Risco de crédito	Boa $\frac{5}{14}$	Alta $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	4/6	6/6	1/6
Moderado 3/14	1/3	1/3	2/3	1/3
Baixo 5/14	3/5	2/5	3/5	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

$$P(Alto|B) = 0{,}113$$

$$P(Moderado|B) = \frac{\left(\frac{1}{3}\right) * \left(\frac{1}{3}\right) * \left(\frac{2}{3}\right) * \left(\frac{1}{3}\right) * \left(\frac{3}{14}\right)}{\left(\frac{5}{14}\right) * \left(\frac{7}{14}\right) * \left(\frac{11}{14}\right) * \left(\frac{7}{14}\right)} = 0{,}075$$

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito	Dívida	Garantias	Renda anual
Risco de crédito	Boa $\frac{5}{14}$	Alta $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	4/6	6/6	1/6
Moderado 3/14	1/3	1/3	2/3	1/3
Baixo 5/14	3/5	2/5	3/5	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

$P(Alto|B) = 0{,}113$
$P(Moderado|B) = 0{,}075$

$$P(Baixo|B) = \frac{\left(\frac{3}{5}\right) * \left(\frac{2}{5}\right) * \left(\frac{3}{5}\right) * \left(\frac{5}{5}\right) * \left(\frac{5}{14}\right)}{\left(\frac{5}{14}\right) * \left(\frac{7}{14}\right) * \left(\frac{11}{14}\right) * \left(\frac{7}{14}\right)} = 0{,}733$$

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito	Dívida	Garantias	Renda anual
Risco de crédito	Boa $\frac{5}{14}$	Alta $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	> 35 $\frac{7}{14}$
Alto 6/14	1/6			1/6
Moderado 3/14	1/3			1/3
Baixo 5/14	3/5	2/5	3/5	5/5

Para chegar na probabilidade do risco ser alto, moderado ou baixo, é necessário normalizar as probabilidades:

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

$P(Alto|B) = 0{,}113$
$P(Moderado|B) = 0{,}075$
$P(Baixo|B) = 0{,}733$

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito	Dívida	Garantias	Renda anual
Risco de crédito	Boa $\frac{5}{14}$	Alta $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	> 35 $\frac{7}{14}$
Alto 6/14	1/6			1/6
Moderado 3/14	1/3			1/3
Baixo 5/14	3/5	2/5	3/5	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

Para chegar na probabilidade do risco ser alto, moderado ou baixo, é necessário normalizar as probabilidades:

$$Soma = 0{,}113 + 0{,}075 + 0{,}733 = 0{,}921$$

$P(Alto|B) = 0{,}113$
$P(Moderado|B) = 0{,}075$
$P(Baixo|B) = 0{,}733$

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito	Dívida	Garantias	Renda anual
Risco de crédito	Boa $\frac{5}{14}$	Alta $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	> 35 $\frac{7}{14}$
Alto 6/14	1/6			1/6
Moderado 3/14	1/3			1/3
Baixo 5/14	3/5	2/5	3/5	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

Para chegar na probabilidade do risco ser alto, moderado ou baixo, é necessário normalizar as probabilidades:

$$Soma = 0{,}113 + 0{,}075 + 0{,}733 = \boxed{0{,}921}$$

$P(Alto|B) = 0{,}113$
$P(Moderado|B) = 0{,}075$
$P(Baixo|B) = 0{,}733$

Normalizando

$$P(Alto|B) = \frac{0{,}113}{0{,}921} * 100 = 12{,}275\%$$

$$P(Moderado|B) = \frac{0{,}113}{0{,}921} * 100 = 8{,}183\%$$

$$P(Baixo|B) = \frac{0{,}113}{0{,}921} * 100 = 79{,}542\%$$

- **Funcionamento**
  - A probabilidade será dada pela aplicação do Teorema de Bayes:

	História do crédito	Dívida	Garantias	Renda anual
Risco de crédito	Boa $\frac{5}{14}$	Alta $\frac{7}{14}$	Nenhuma $\frac{11}{14}$	> 35 $\frac{7}{14}$
Alto 6/14	1/6	4/6	6/6	1/6
Moderado 3/14	1/3	1/3	2/3	
Baixo 5/14	3/5	2/5	3/5	5/5

História = Boa
Dívida = Alta
Garantias = Nenhuma
Renda = > 35

$$Soma = 0{,}113 + 0{,}075 + 0{,}733 = 0{,}921$$

Podemos afirmar que o novo registro possui 79,54% de probabilidade de ser de baixo risco!

$P(Alto|B) = 0{,}113$
$P(Moderado|B) = 0{,}075$
$P(Baixo|B) = 0{,}733$

Normalizando

$$P(Alto|B) = \frac{0{,}113}{0{,}921} * 100 = 12{,}275\%$$

$$P(Moderado|B) = \frac{0{,}113}{0{,}921} * 100 = 8{,}183\%$$

$$P(Baixo|B) = \frac{0{,}113}{0{,}921} * 100 = \boxed{79{,}542\%}$$

- **Construindo o script**

  – Primeiramente, o script de pré-processamento deve ser executado, selecionando quais as transformações precisam ser feitas na base.

Spyder (Python 3.7)

Arquivo Editar Pesquisar Código Executar Depurar Consoles Projetos Ferramentas Ver Ajuda

...ofessor\CEFET\2020-1_Técnicas de Aprendizado de Máquina\Aulas\aula 4\Programas\pre-processamento.py

acao_dados_climaticos_RJ.py | KNN.py | KNN-configuração.py | pre-processamento.py

```python
import pandas as pd

################## #Pré-processamento dos dados ##################

#Leitura dos dados
base = pd.read_csv('credit_data.csv')
base.describe()

# Procurando valores inconsistentes
base.loc[base['Age'] < 0]

# Apagar a coluna
# base.drop('Age', 1, inplace=True)

# Apagar apenas os registros com problema
# base.drop(base[base.Age < 0].index, inplace=True)

# Preencher os valores com a média
age_media = base['Age'][base.Age > 0].mean()
base.loc[base.Age < 0, 'Age'] = age_media

# Procurando as colunas que possuem algum valor faltante
pd.isnull(base).any()

# Preencher os valores com o mais frequente
saving_maioria = base['Saving accounts'][pd.notnull(base['Saving accoun
base.loc[pd.isnull(base['Saving accounts']), 'Saving accounts'] = savin
```

:nicas de Aprendizado de Máquina\Aulas\aula 4\Programas

Nome	Tipo	Tamanho	
age_media	float	1	35.5
base	DataFrame	(1000, 11)	Colu
checking_maior…	str	1	litt
classe	DataFrame	(1000, 1)	Colu Risk
classe_teste	DataFrame	(250, 1)	Colu Risk
classe_treinam…	DataFrame	(750, 1)	Colu Risk
cols_classe	list	1	['Ri

Ajuda | Explorador de variáveis | Figuras | Arquivos

Console 1/A

```
sores.loc[:, 'Saving accounts'])
   ...: previsores.loc[:, 'Purpose'] =
labelencoder_previsores.fit_transform(previ
sores.loc[:, 'Purpose'])
   ...: classe.loc[:,'Risk'] =
labelencoder_previsores.fit_transform(class
e.loc[:, 'Risk'])
   ...:
   ...: # As variáveis categóricas que não
possuem ordenamento precisam ser tratadas
   ...: # Transformando categorias em
```

Console IPython | Histórico

Kite: ready | conda: base (Python 3.7.0) | Line 83, Col 1 | UTF-8 | CRLF | RW | Mem 61%

- **Construindo o script**
  - Para executar o Naive-Bayes, crie um novo arquivo chamado “naive-bayes.py”.
  - Nele, insira o seguinte código:

```
################## Classificação com Naive Bayes ##################

from sklearn.naive_bayes import GaussianNB
classificador = GaussianNB()

# Treinamento (automaticamente o sklearn já faz a correção laplaciana)
classificador.fit(previsores_treinamento, classe_treinamento)

# Teste
previsoes = classificador.predict(previsores_teste)

# Análise dos resultados (porcentagem de acertos e MATRIZ DE CONFUSÃO)
from sklearn.metrics import confusion_matrix, accuracy_score
acuracia_teste = accuracy_score(classe_teste, previsoes)
matriz_teste = confusion_matrix(classe_teste, previsoes)
```

- **Construindo o script**
  - Para executar o Naive-Bayes, crie um novo arquivo chamado “naive-bayes.py”.
  - Nele, insira o seguinte código:

```
################### Classificação com Naive Bayes ###################

from s
classi

# Treinamento (automaticamente o sklearn já faz a correção laplaciana)
classificador.fit(previsores_treinamento, classe_treinamento)

# Teste
previsoes = classificador.predict(previsores_teste)

# Análise dos resultados (porcentagem de acert
from sklearn.metrics import confusion_matrix,
acuracia_teste = accuracy_score(classe_teste,
matriz_teste = confusion_matrix(classe_teste, previsoes)
```

matriz_teste	Array of int64	(2, 2)	[[25 49] [23 153]]
acuracia_teste	float64	1	0.712

Precisamos registrar este resultado para futuras comparações!

- **Registrando os resultados**
  - Neste teste, o **LabelBinarizer** e a **padronização** de dados não foram aplicados.
  - Nesta configuração, o resultado não foi melhor que o obtido pelo KNN.

Dados de Crédito	
Descrição	Nesse conjunto de dados, cada entrada representa uma pessoa que recebe um crédito por um banco. Cada pessoa é classificada como risco de crédito bom ou ruim, de acordo com o conjunto de atributos.
Total de registros:	1000
Total de características:	9
Total de colunas de classes:	1

Resultados				
Método	Configuração	Tratamento de dados	Acurácia %	Matriz de Confusão
KNN	K = 32, Distância Euclidiana	Padronização, OneHotEncoder	0,716	9 65 6 170
Naive Bayes	Gaussiana	-	0,712	25 49 23 153

Naive Bayes

- **Noções básicas de estatística**
  - O Naive Bayes alcança seus melhores resultados quando a **correlação entre as variáveis** é próxima de **zero**.
  - Em alguns casos, se for identificada **alta correlação** entre dados de **duas colunas**, pode ser interessante **remover uma delas** da base de dados.
  - A **alta correlação** pode indicar que ambas contribuem de **forma similar** com a classificação, criando **redundância** dos cálculos e excesso de **custo computacional**.

- **Noções básicas de estatística**
  - Para **identificar** colunas com esta característica, podemos plotar a matriz de **Correlação de Pearson**.
  - Em um novo arquivo, faça:

```
import pandas as pd
import numpy as np


###################### Descobrindo maiores correlações com objetivo ##############################
#  Executar antes da padronização


# Considerando todas as características
base_caracteristicas_e_objetivo = pd.concat([previsores, classe], axis=1)

corr = base_caracteristicas_e_objetivo.corr()

#  plotar matriz de correlação de pearson
import seaborn as sns
ax = sns.heatmap(
    corr,
    vmin=-1, vmax=1, center=0,
    cmap=sns.diverging_palette(20, 220, n=200),
    square=True,
    xticklabels=True,
    yticklabels=True
)
ax.set_xticklabels(
    ax.get_xticklabels(),
    rotation=45,
    horizontalalignment='right'
);

###################### Detectando e lindando com multicolinearidade com VIF ######################
```

- **Noções básicas de estatística**
  - Na base atual, a matriz fica assim:

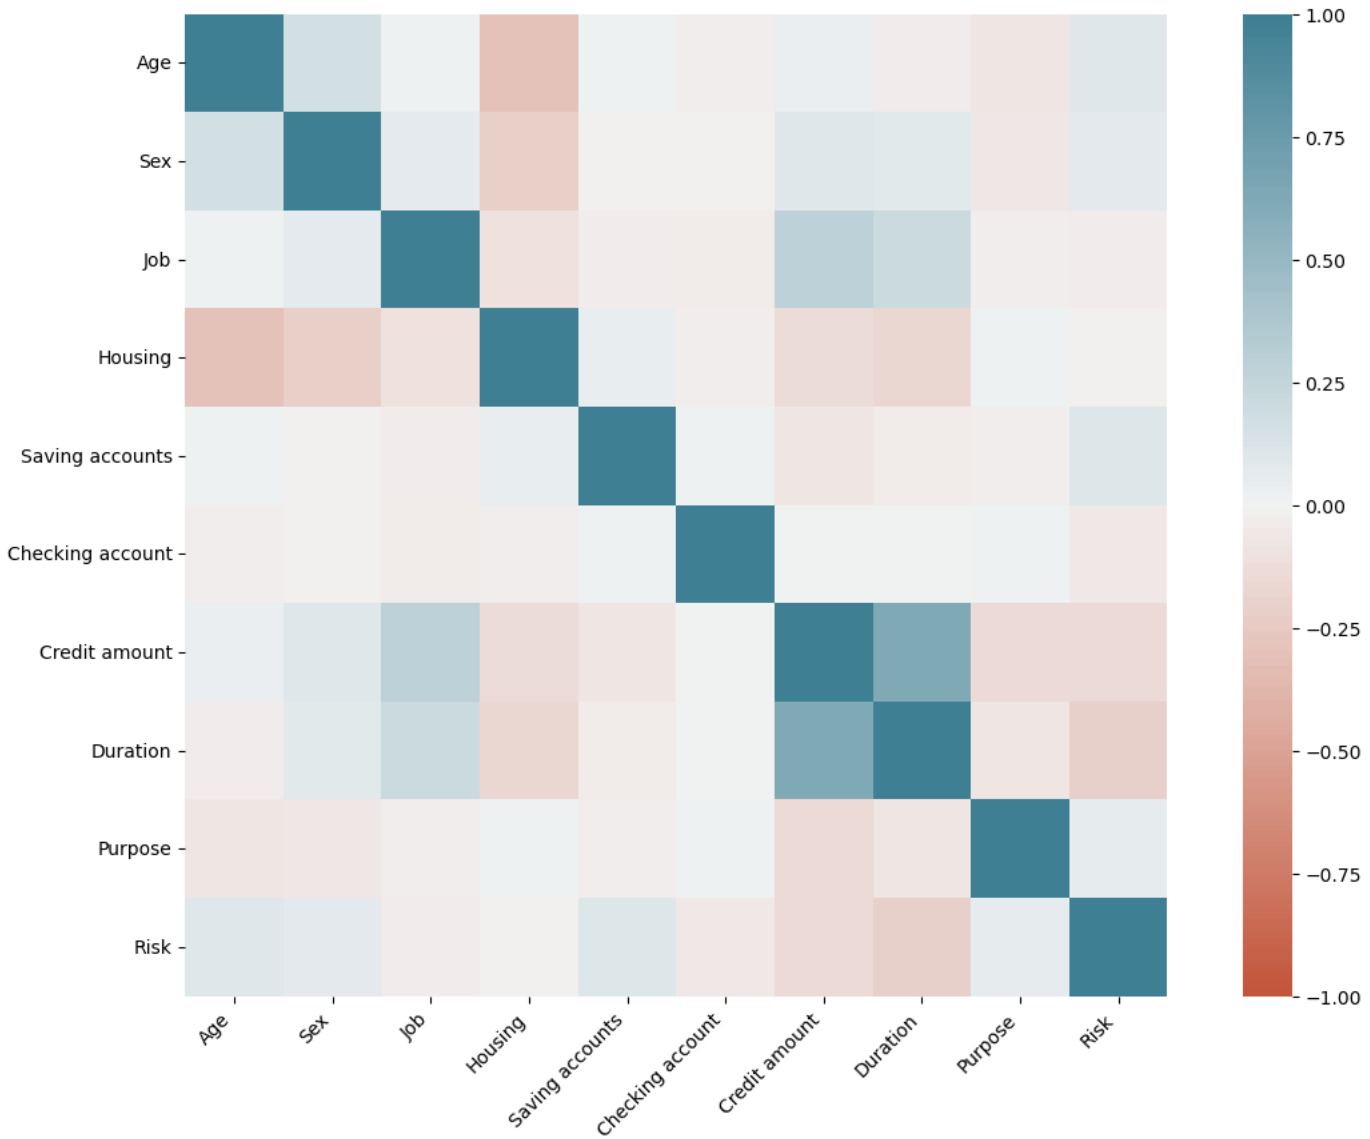

- **Noções básicas de estatística**
  - Na base atual, a matriz fica assim:

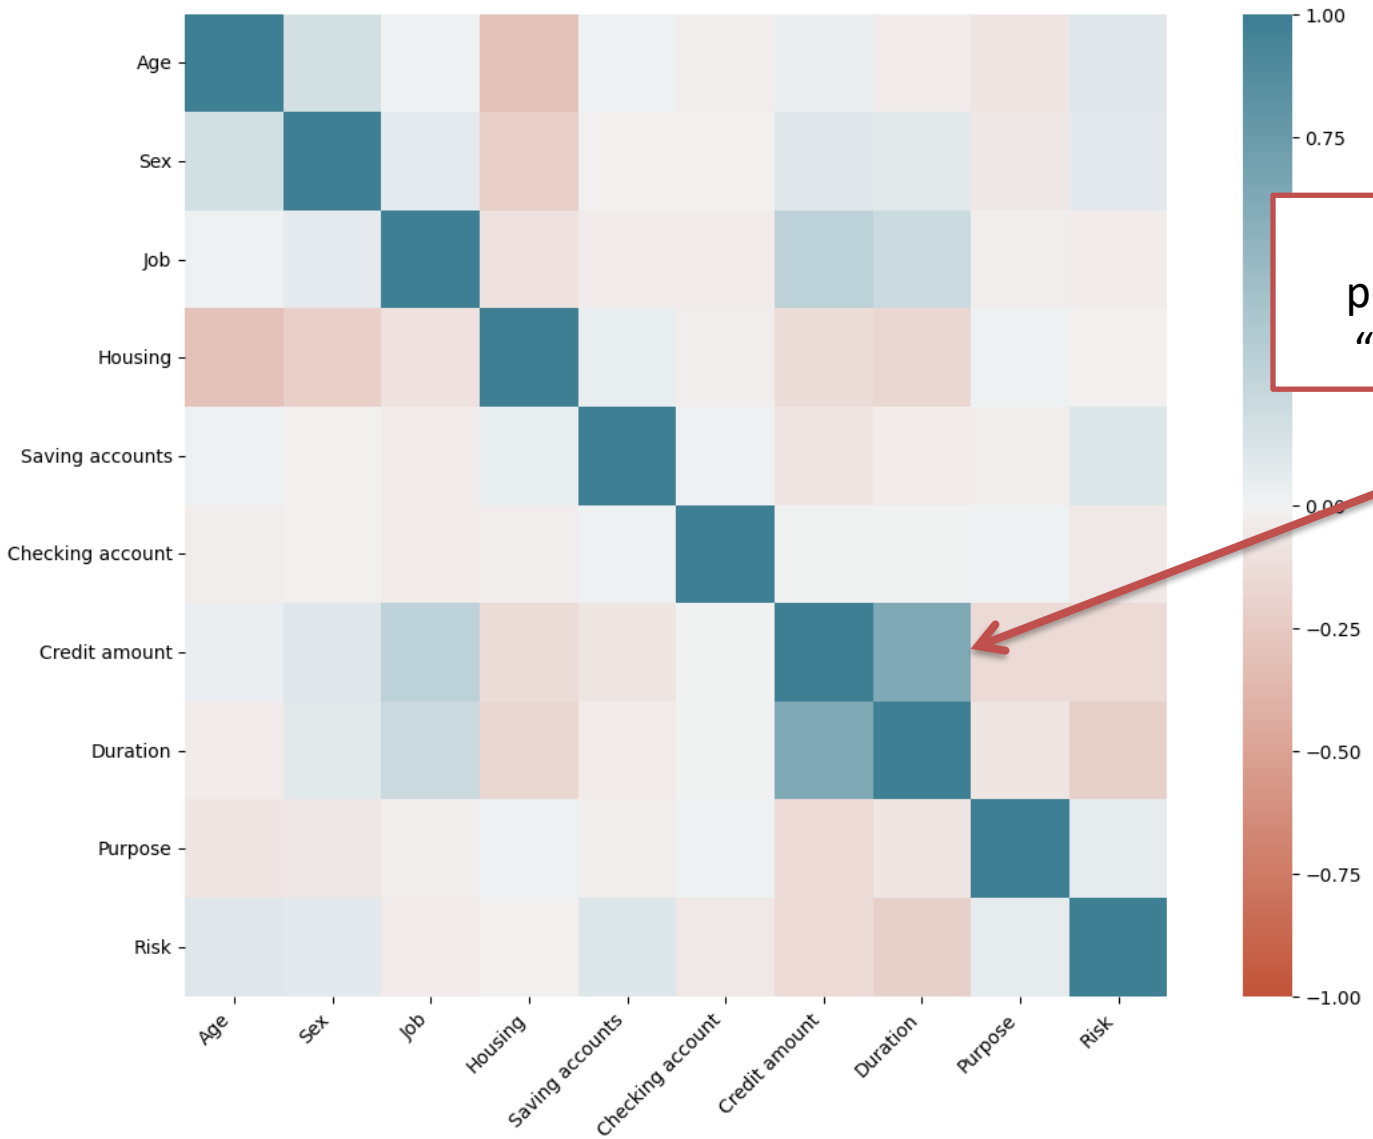

As únicas colunas que talvez possuam alta correlação são as “Credit amount” e “Duration”.

- **Noções básicas de estatística**

  – Como teste, vamos remover a coluna “Duration” e criar um novo arquivo de base de dados, alterado:

```
######################## Removendo colunas correlacionadas ######################

base = pd.read_csv('credit_data.csv')
nova_base = base.drop('Duration', 1)


# ==========================================================================
#                        SALVANDO BASE EM ARQUIVO
# ==========================================================================

pd.DataFrame.to_csv(nova_base, 'credit_data_reduzida.csv', index=False)

##########################################################################
```

  – Executando o Naive Bayes na nova base, chegamos ao seguinte resultado:

acuracia_teste	float64	1	0.704
matriz_teste	Array of int64	(2, 2)	[[17 57] [17 159]]

- **Registrando os resultados**
  - Neste caso, o resultado não foi melhor que o obtido anteriormente.
  - De qualquer forma, devemos registrar este resultado para futuras comparações:

Dados de Crédito	
Descrição	Nesse conjunto de dados, cada entrada representa uma pessoa que recebe um crédito por um banco. Cada pessoa é classificada como risco de crédito bom ou ruim, de acordo com o conjunto de atributos.
Total de registros:	1000
Total de características:	9
Total de colunas de classes:	1

Resultados

Método	Configuração	Tratamento de dados	Acurácia %	Matriz de Confusão
Classe Majoritária	-	-	0.704	0 74 0 176
KNN	K = 35, Distância Euclidiana	Padronização, Transformação em variáveis numéricas, dummy	0.724	7 67 2 174
KNN	K = 19, Distância Euclidiana	Padronização, Transformação em variáveis numéricas	0.728	11 63 5 171
Naive Bayes	-	Padronização, Transformação em variáveis numéricas,	0.708	25 49 24 152
Naive Bayes	-	Transformação em variáveis numéricas, removida coluna Duration	0.704	17 57 17 159

FIM