Risco Biológico e Aprendizado de Máquina

Kauã Alves Santos | Mateus Vinicius Zebendo Pinto

CEFET/RJ - Campus Nova Friburgo | Disciplina: Técnicas de Aprendizado de Máquina

Otimização de Falsos Negativos na Classificação de Cogumelos Agaricus e Lepiota

1. Contexto e Desafio Fundamental

O Risco Biológico Letal

A ingestão acidental de cogumelos venenosos representa uma ameaça crítica à vida humana. O estudo foca na automação rigorosa da identificação para mitigar este risco.

Base de Dados: Mushroom Classification

Criado por Jeffrey Schlimmer (1987), o dataset contém **8.124 registros** de espécimes "gilled" (lamelados) das famílias **Agaricus** e **Lepiota**.

Objetivo Central: Encontrar o algoritmo que maximize a **Revocação (Recall)**, penalizando severamente os Falsos Negativos (classificar um tóxico como comestível).

Espécime tóxico classificado como inofensivo

ERRO CRÍTICO

Falso Negativo

2. Biologia e Anatomia do Cogumelo Lamelado

O estudo identifica estruturas morfológicas chave descritas na **Figura 1** do artigo para a distinção de toxicidade:

- **Chapéu (Píleo):** Parte superior; pode apresentar escamas.
- **Lamelas (Gills):** Estrutura pregueada sob o píleo onde ficam os esporos.
- **Anel:** Resto de véu parcial no estipe após a abertura do píleo.
- **Estipe (Caule):** Estrutura de sustentação central.
- **Volva:** Resto de véu universal na base do estipe.
- **Micélio:** Conjunto de hifas no substrato (corpo vegetativo).

*Família **Lepiota**: Frequentemente contém amatoxinas letais e apresenta escamas no píleo.*

3. Estado da Arte e Discussão Acadêmica

A literatura divide-se entre dados estruturados (tabulares) e visão computacional (imagens):

Estudo / Autor	Foco / Método	Resultado Principal
Wibowo et al. (2018)	DT vs SVM vs Naive Bayes	DT e SVM atingiram 100% de acurácia.
Hamonangan (2021)	Otimização KNN (k=1)	Atingiu 100% de precisão inicial.
Sahu et al. (2024)	Ensemble Learning (AdaBoost)	AdaBoost superior (95,35%) a modelos únicos.
Mathur et al. (2026)	Atenção Analítica	Acurácia de 99,9% com reprodutibilidade determinística.
Chitayae & Sunyoto (2020)	KNN vs Algoritmo CART	CART superior (91,93%) ao KNN (89,61%).

Diferencial deste estudo: Rompimento com a Acurácia Global; foco exclusivo em **Risco Zero** na classe tóxica.

4. Rigor Metodológico: Preparação dos Dados

Tratamento de Dados Ausentes

A variável **stalk-root** apresentava valores '?'. Optou-se pela imputação da categoria **"desconhecido"** para que o modelo interprete a ausência como característica preditiva.

Codificação (Encoding)

- **Label Encoding:** Classe alvo mapeada (Venenoso = 1, Comestível = 0).
- **One-Hot Encoding:** Conversão de variáveis nominais. Remoção da primeira categoria para evitar a **Dummy Variable Trap**.

Vetor de Features Final

A dimensionalidade passou de **22 variáveis originais** para um vetor denso de **95 features**, garantindo independência linear.

Normalização e Prevenção de Leakage

Aplicação de **Z-score normalization** (média zero, desvio padrão 1). Parâmetros extraídos exclusivamente do treino para evitar **Data Leakage**.

5. Algoritimos Avaliadas

Foram testados seis paradigmas de aprendizado supervisionado via **Scikit-Learn**:

KNN

Distância Euclidiana; Lazy Learner.

NAIVE BAYES

Gaussian, Bernoulli e Complement.

ÁRVORE DE DECISÃO

Particionamento via Entropia/Gini.

RANDOM FOREST

Ensemble; múltiplas DTs via Bagging.

SVM

Kernels Linear, RBF e Sigmoid.

REDES NEURAIS

Multi-Layer Perceptron (Backprop).

Validação: Validação Cruzada Estratificada (**Stratified 5-Fold**) e Busca em Grade (**GridSearchCV**) focada na maximização da Revocação.

6. Desempenho Global e Configurações Ótimas

Resultados sumarizados para 1.625 instâncias de teste (783 venenosos):

Algoritmo	Configuração Principal	Acurácia	Matriz de Confusão (VN FP / FN VP)
KNN	K = 5	99,88%	842 0 / 2 781
Naive Bayes	Gaussian	94,95%	762 80 / 2 781
Naive Bayes	Bernoulli	92,86%	834 8 / 108 675
Árvore de Decisão	**max_depth = 8**	**100,00%**	**842 0 / 0 783**
SVM	kernel = 'sigmoid'	98,58%	835 7 / 16 767
Redes Neurais	hidden_layer_sizes = [10]	99,88%	842 0 / 2 781

Análise Crítica: A alta acurácia (98%+) do KNN e MLP oculta 2 Falsos Negativos fatais.

7. Análise da Revocação e Risco Residual

Métricas focadas na **Classe Venenosa (Positiva)**:

Algoritmo	Revocação	F. Negativos
KNN (K=5)	99,74%	2
Naive Bayes (Ber)	86,21%	108
Árvore Decisão (d=8)	**100,00%**	**0**
Random Forest	99,74%	2
SVM (Sigmoid)	97,96%	16

O **Naive Bayes (Bernoulli)** falhou severamente (108 FN), provando que a suposição de independência entre variáveis binárias é inadequada para capturar padrões tóxicos complexos.

8. A Escolha da Árvore de Decisão (d=8)

Recall: 1,0000

± 0,0000 em Validação Cruzada

Princípio da Parcimônia (Navalha de Ockham):

- Entre modelos de performance idêntica (RF e MLP), a Árvore de Decisão é a mais simples.
- **Transparência:** Rejeita o obscurantismo das "caixas-pretas".
- **Custo:** Fração do custo computacional de redes profundas.

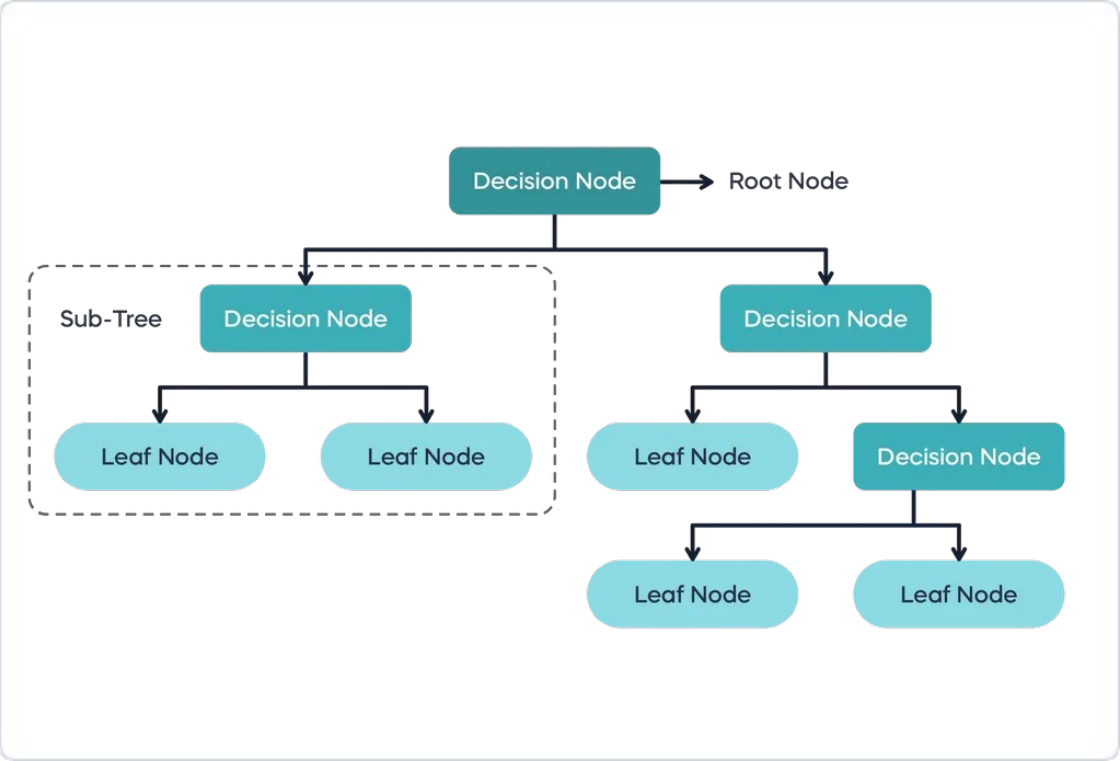

A profundidade 8 foi exata para isolar as exceções morfológicas sem gerar **Overfitting**.

9. Vetores de Decisão e Explicabilidade

Quantificação do peso matemático das variáveis biológicas (Tabela 3):

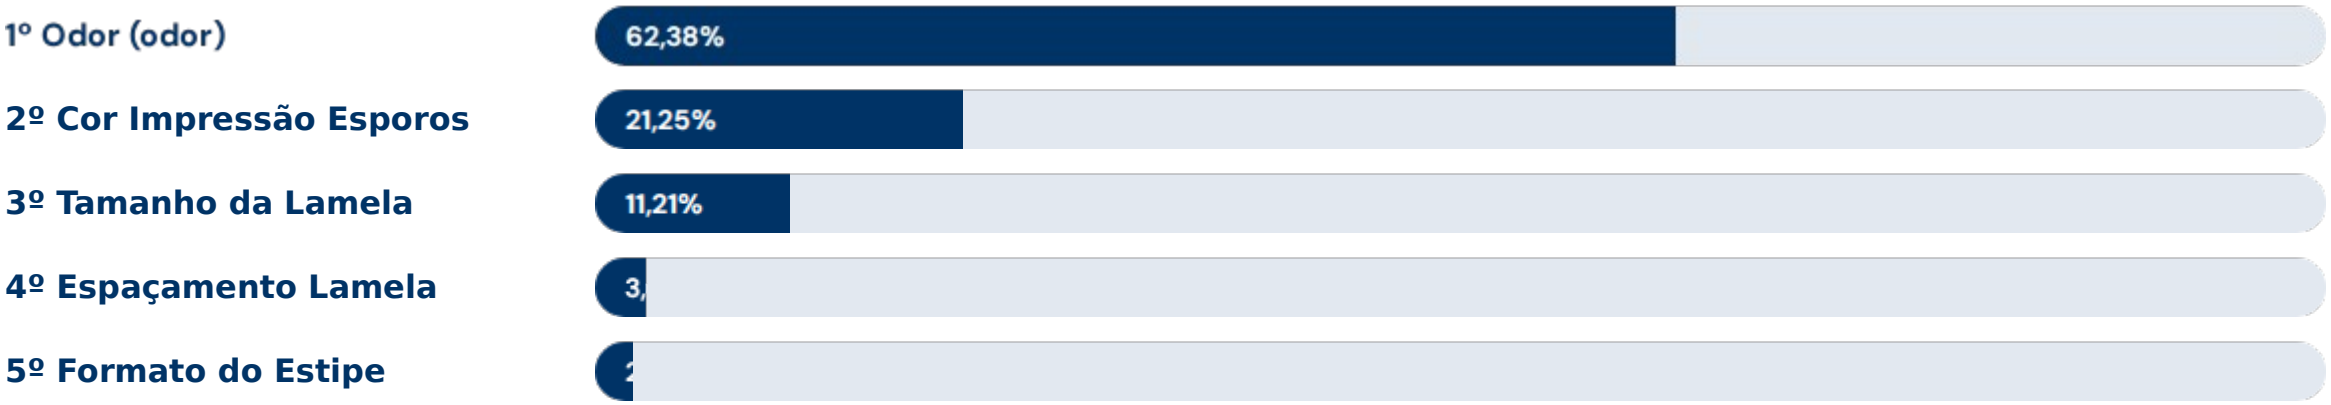

> O **Odor** atua como a principal linha de defesa lógica. Onde há ambiguidade olfativa, o modelo recorre à morfologia reprodutiva (cor dos esporos) e física (lamelas).

10. Conclusões e Segurança Biológica

- **Eficácia:** As características morfológicas catalogadas possuem padrão informacional forte o suficiente para mitigar o risco humano.
- **Métrica Soberana:** Em saúde e segurança, a Revocação absoluta é o único critério de sucesso
- **Inovação:** O modelo supera o estado da arte ao priorizar a contenção de risco (Recall 100%) em vez da acurácia global.

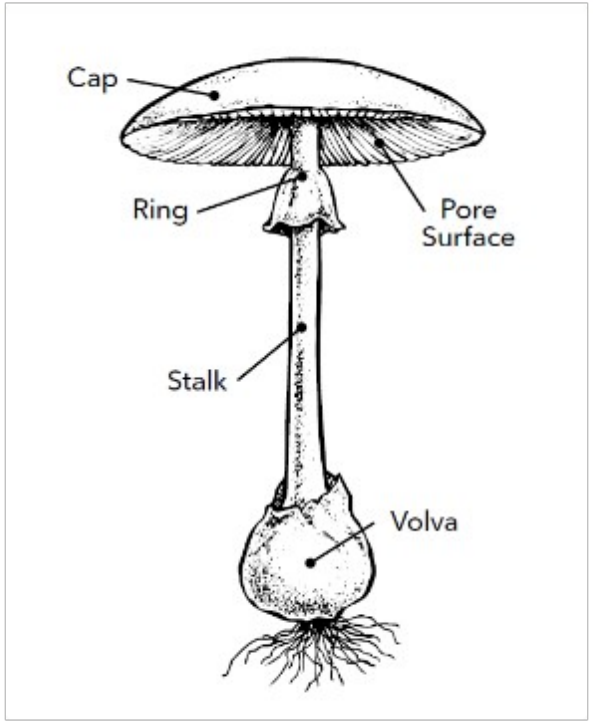

IA na Micologia: Risco de letalidade mitigado quase na totalidade.

Dúvidas?

Obrigado pela atenção!

Kauã Alves Santos

Mateus Vinicius Z. Pinto:r

github.com/mateuszebendo/tecnicas-de-machine-learning